

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
TP. HO CHI MINH

JAILBREAKING LARGE LANGUAGE MODELS AND AGENTIC SYSTEMS

23120245	Nguyễn Quang Duy
23120258	Lưu Trọng Hiếu
23120260	Văn Đình Hiếu

Môn học: Nhập môn Học máy
Thành phố Hồ Chí Minh – 2026

Tóm tắt

Sự phát triển nhanh chóng của các mô hình ngôn ngữ lớn (Large Language Models – LLMs) đã thúc đẩy việc ứng dụng trí tuệ nhân tạo vào nhiều lĩnh vực như trợ lý hội thoại, hỗ trợ lập trình, tìm kiếm thông tin, tự động hóa quy trình và các hệ thống tác tử có khả năng sử dụng công cụ. Cùng với sự mở rộng về năng lực, vấn đề bảo đảm mô hình tuân thủ các nguyên tắc an toàn và không tạo ra hành vi ngoài mong muốn trở thành một yêu cầu quan trọng. Tuy nhiên, các cơ chế căn chỉnh an toàn hiện nay vẫn có thể bị vượt qua bởi các kỹ thuật jailbreaking, trong đó đầu vào được xây dựng hoặc tối ưu nhằm khiến mô hình không tuân theo những ràng buộc an toàn đã được thiết lập.

Báo cáo này tổng hợp nội dung của tutorial *Jailbreaking LLMs and Agentic Systems: Attacks, Defenses, and Evaluations*. Trước hết, báo cáo trình bày kiến thức nền về mô hình ngôn ngữ lớn, instruction tuning, alignment và threat model trong nghiên cứu an toàn mô hình. Tiếp theo, các phương pháp jailbreak được hệ thống hóa theo quyền truy cập của kẻ tấn công, mức độ tự động hóa, cơ chế tìm kiếm và số lượt tương tác. Các hướng phòng thủ được phân loại theo vị trí triển khai, bao gồm xử lý đầu vào, điều chỉnh mô hình, phòng thủ trong quá trình suy luận, kiểm duyệt đầu ra và bảo vệ ở cấp hệ thống.

Báo cáo đồng thời khảo sát các benchmark và tiêu chí đánh giá như Attack Success Rate, refusal rate, over-refusal rate và benign utility. Ngoài các chatbot dựa trên văn bản, báo cáo mở rộng phân tích sang agentic systems và robot được điều khiển bởi LLM, nơi một cuộc tấn công thành công có thể không chỉ thay đổi nội dung phản hồi mà còn tác động đến quá trình lập kế hoạch, gọi công cụ và thực hiện hành động. Cuối cùng, nhóm trình bày thiết kế demo thực nghiệm nhằm so sánh một số phương pháp tấn công và phòng thủ trong môi trường kiểm soát, đồng thời phân tích sự đánh đổi giữa độ an toàn, khả năng hữu ích và chi phí tính toán của hệ thống.

Từ khóa: mô hình ngôn ngữ lớn, jailbreaking, alignment, an toàn trí tuệ nhân tạo, adversarial attack, jailbreak defense, automated red teaming, agentic systems.

Mục lục

Tóm tắt	i
Danh mục từ viết tắt	v
Danh mục hình vẽ	vi
Danh mục bảng	vii
1 Giới thiệu	1
1.1 Bối cảnh nghiên cứu	1
1.2 Bài toán jailbreaking	1
1.3 Mục tiêu báo cáo	2
1.4 Phạm vi báo cáo	2
1.5 Cấu trúc báo cáo	3
2 Kiến thức nền	3
2.1 Mô hình ngôn ngữ lớn	3
2.2 Instruction tuning và safety alignment	4
2.3 Thứ bậc chỉ dẫn trong hệ thống LLM	5
2.4 Threat model trong nghiên cứu jailbreak	6
2.5 Phân biệt các khái niệm an toàn liên quan	7
2.6 Safety–utility trade-off	8
2.7 Từ chatbot đến agentic systems	9
3 Jailbreak Attacks	10
3.1 Taxonomy các phương pháp jailbreak	10
3.2 Manual và template-based attacks	13
3.3 Obfuscation và encoding attacks	13
3.4 Multi-turn jailbreak	14
3.5 White-box optimization	15
3.6 Black-box automated jailbreak	15
3.7 Transferability	16
3.8 Adaptive attacks	17
3.9 Tổng kết chương	17
4 Jailbreak Defenses	18
4.1 Taxonomy các phương pháp phòng thủ	18
4.2 Input filtering	19
4.3 Prompt preprocessing	20
4.4 Adversarial training	20

4.5	Inference-time defenses	21
4.6	Output moderation	22
4.7	Representation-level defenses	22
4.8	Guard models	23
4.9	Defense-in-depth	23
4.10	Hạn chế của các phương pháp phòng thủ	24
4.11	Tổng kết chương	25
5	Evaluation and Benchmarks	25
5.1	Mục tiêu đánh giá	26
5.2	Attack Success Rate	26
5.3	Refusal và harmfulness	27
5.4	Utility và over-refusal	28
5.5	Human evaluation	28
5.6	Classifier-based evaluation	29
5.7	LLM-as-a-judge	29
5.8	AdvBench	30
5.9	HarmBench	31
5.10	JailbreakBench	31
5.11	So sánh các benchmark	32
5.12	Đánh giá trong agentic systems	32
5.13	Hạn chế chung của evaluation hiện tại	33
5.14	Tổng kết chương	34
6	Agentic Systems	34
6.1	Tổng quan LLM agents	35
6.2	Bề mặt tấn công của agent	35
6.3	Prompt injection trực tiếp và gián tiếp	36
6.4	Tool-use attacks	37
6.5	Memory poisoning	38
6.6	Jailbreaking LLM-controlled robots	38
6.7	Agent-specific defenses	39
6.8	Benchmark cho agent security	40
6.9	Tổng kết chương	41
7	Các công trình tiêu biểu trong tutorial	42
7.1	Các công trình về jailbreak attacks	42
7.1.1	Universal and Transferable Adversarial Attacks	42
7.1.2	PAIR	43
7.1.3	Tree of Attacks	43

7.1.4	AutoDAN	44
7.1.5	Automated red teaming và reasoning-based search	44
7.2	Các công trình về jailbreak defenses	44
7.2.1	SmoothLLM	45
7.2.2	Circuit Breakers	45
7.2.3	Representation Guardrails	46
7.2.4	Instruction-following và utility evaluation	46
7.3	Các benchmark và phương pháp đánh giá	46
7.3.1	AdvBench	46
7.3.2	HarmBench	47
7.3.3	JailbreakBench	47
7.3.4	Trojan Detection Challenge	47
7.4	Các công trình về robotics và agentic systems	47
7.4.1	RoboPAIR	48
7.4.2	AgentDojo	48
7.4.3	BrowserART và Breaking ReAct	48
7.5	So sánh các công trình tiêu biểu	49
7.6	Nhận xét chung	51
7.7	Tổng kết chương	51
Tài liệu tham khảo		53

Danh mục từ viết tắt

Từ viết tắt	Ý nghĩa
AI	Artificial Intelligence – Trí tuệ nhân tạo
API	Application Programming Interface – Giao diện lập trình ứng dụng
ASR	Attack Success Rate – Tỷ lệ tấn công thành công
GCG	Greedy Coordinate Gradient
ICML	International Conference on Machine Learning
LLM	Large Language Model – Mô hình ngôn ngữ lớn
MLLM	Multimodal Large Language Model – Mô hình ngôn ngữ lớn đa phương thức
PAIR	Prompt Automatic Iterative Refinement
ReAct	Reasoning and Acting
RLHF	Reinforcement Learning from Human Feedback
SFT	Supervised Fine-Tuning
TAP	Tree of Attacks with Pruning
TDC	Trojan Detection Challenge

Danh sách hình vẽ

- 1 Thứ bậc chỉ dẫn và vị trí của nội dung bên ngoài trong ứng dụng LLM. . 6
- 2 Kiến trúc phòng thủ nhiều lớp cho hệ thống LLM có khả năng gọi công cụ. 24

Danh sách bảng

1	Các chiều chính của threat model trong nghiên cứu jailbreak.	7
2	Phân biệt jailbreaking với các khái niệm an toàn liên quan.	8
3	So sánh bề mặt an toàn của chatbot và agentic system.	10
4	Các nhóm phương pháp jailbreak được phân tích trong chương này. . . .	12
5	Taxonomy các phương pháp phòng thủ trước jailbreak.	19
6	Quan hệ giữa refusal và harmfulness trong đánh giá phản hồi.	27
7	So sánh khái quát AdvBench, HarmBench và JailbreakBench.	32
8	Bề mặt tấn công chính trong hệ thống LLM agent.	36
9	Các nhóm phòng thủ đặc thù cho agentic systems.	40
10	Các công trình tiêu biểu được tutorial đề cập theo từng nhóm nội dung. .	50

1 Giới thiệu

1.1 Bối cảnh nghiên cứu

Trong những năm gần đây, các mô hình ngôn ngữ lớn (Large Language Models – LLMs) đã trở thành thành phần quan trọng trong nhiều ứng dụng như trợ lý hội thoại, hỗ trợ lập trình, tìm kiếm thông tin, phân tích tài liệu và tự động hóa quy trình. Khi được kết hợp với bộ nhớ, khả năng lập kế hoạch và cơ chế gọi công cụ, LLM không chỉ sinh phản hồi dạng văn bản mà còn có thể đóng vai trò như bộ điều khiển của các hệ thống tác tử thông minh, thường được gọi là *agentic systems*.

Sự mở rộng này làm tăng đáng kể yêu cầu về an toàn. Một chatbot truyền thống chủ yếu tạo ra phản hồi văn bản, trong khi một agentic system có thể truy xuất dữ liệu, gọi API, thao tác trên tệp hoặc tương tác với môi trường bên ngoài. Do đó, một hành vi không an toàn trong hệ thống tác tử có thể dẫn đến hậu quả nghiêm trọng hơn so với một phản hồi văn bản không phù hợp.

Để giảm thiểu rủi ro, các LLM hiện đại thường được căn chỉnh bằng nhiều kỹ thuật như supervised fine-tuning, preference optimization, Reinforcement Learning from Human Feedback (RLHF) và safety fine-tuning. Bên cạnh đó, hệ thống triển khai còn có thể sử dụng system prompt, bộ lọc đầu vào, bộ phân loại an toàn và kiểm duyệt đầu ra. Tuy nhiên, các cơ chế này chưa tạo ra bảo đảm tuyệt đối. Nhiều nghiên cứu cho thấy hành vi từ chối của mô hình vẫn có thể bị làm suy yếu bởi các đầu vào được thiết kế có chủ đích, gọi chung là *jailbreak attacks* [1], [2], [3].

1.2 Bài toán jailbreaking

Trong phạm vi báo cáo này, jailbreaking được hiểu là quá trình xây dựng hoặc tối ưu đầu vào nhằm khiến một mô hình đã được căn chỉnh an toàn tạo ra hành vi trái với các ràng buộc mà nhà phát triển đặt ra. Kẽ tấn công không nhất thiết phải thay đổi tham số hoặc dữ liệu huấn luyện của mô hình; trong nhiều trường hợp, họ chỉ có quyền gửi truy vấn và quan sát phản hồi của hệ thống.

Một cách khái quát, hệ thống LLM có thể được biểu diễn bởi

$$y = F_{\theta}(x, s, c), \quad (1)$$

trong đó x là yêu cầu của người dùng, s là system prompt hoặc chính sách hệ thống, c là ngữ cảnh bổ sung và F_{θ} là mô hình với tham số θ . Jailbreak attack tìm một phép biến đổi $\mathcal{T}$ sao cho

$$x' = \mathcal{T}(x), \quad (2)$$

trong đó x' vẫn giữ mục tiêu ngữ nghĩa của yêu cầu ban đầu nhưng khiến đầu ra của hệ thống không còn thuộc tập phản hồi an toàn:

$$F_{\theta}(x', s, c) \notin \mathcal{V}_{\text{safe}}. \quad (3)$$

Jailbreaking có liên hệ với prompt injection nhưng không hoàn toàn đồng nhất. Jailbreaking thường tập trung vào việc vượt qua các ràng buộc an toàn của mô hình, trong khi prompt injection nhắm đến việc làm thay đổi thứ tự ưu tiên hoặc luồng thực thi chỉ dẫn trong một ứng dụng dùng LLM. Trong agentic systems, hai dạng rủi ro này có thể xuất hiện đồng thời.

1.3 Mục tiêu báo cáo

Báo cáo này được xây dựng dựa trên tutorial ICML 2025 *Jailbreaking LLMs and Agentic Systems: Attacks, Defenses, and Evaluations* [4]. Mục tiêu chính là hệ thống hóa các nội dung nền tảng về jailbreaking, bao gồm threat model, phương pháp tấn công, phương pháp phòng thủ, cách đánh giá và sự mở rộng của bài toán sang agentic systems.

Cụ thể, báo cáo tập trung vào các mục tiêu sau:

- M1.** Trình bày nền tảng về LLM, instruction tuning, safety alignment và threat model.
- M2.** Hệ thống hóa các nhóm jailbreak attacks theo cơ chế xây dựng prompt, quyền truy cập và số lượt tương tác.
- M3.** Phân tích các lớp phòng thủ đối với jailbreak ở cấp đầu vào, mô hình, suy luận, đầu ra và toàn hệ thống.
- M4.** Trình bày các metric, evaluator và benchmark thường dùng để đánh giá jailbreak.
- M5.** Làm rõ sự khác biệt giữa jailbreak trên chatbot và jailbreak trên agentic systems.
- M6.** Xây dựng demo thực nghiệm trong môi trường kiểm soát để minh họa attack–defense pipeline.

1.4 Phạm vi báo cáo

Báo cáo tập trung vào jailbreaking tại thời điểm suy luận đối với các LLM đã được huấn luyện và triển khai. Nội dung chính bao gồm jailbreak trên LLM sinh văn bản, white-box và black-box attacks, single-turn và multi-turn attacks, automated red teaming, các lớp

phòng thủ, benchmark đánh giá, prompt injection trong agentic systems và jailbreaking đối với robot được điều khiển bởi LLM.

Báo cáo không nhằm bao quát toàn bộ lĩnh vực adversarial machine learning. Các chủ đề như data poisoning, model extraction, membership inference, backdoor trong huấn luyện và tấn công hạ tầng chỉ được nhắc đến khi cần phân biệt với jailbreaking. Phần demo được thực hiện trong môi trường kiểm soát, với mục tiêu nghiên cứu và đánh giá an toàn.

1.5 Cấu trúc báo cáo

Phần còn lại của báo cáo được tổ chức như sau. Chương 2 trình bày kiến thức nền về LLM, instruction tuning, safety alignment và threat model. Chương 3 hệ thống hóa các phương pháp jailbreak, bao gồm manual attacks, obfuscation, multi-turn jailbreak, white-box optimization, black-box automated jailbreak, transferability và adaptive attacks. Chương 4 phân tích các phương pháp phòng thủ như input filtering, adversarial training, inference-time defenses, output moderation, guard models và defense-in-depth.

Chương 5 trình bày các phương pháp đánh giá và benchmark, bao gồm Attack Success Rate, refusal, harmfulness, utility, over-refusal, human evaluation, classifier-based evaluation, LLM-as-a-judge, AdvBench, HarmBench và JailbreakBench. Chương 6 mở rộng bài toán sang agentic systems, bao gồm prompt injection, tool-use attacks, memory poisoning, LLM-controlled robots và agent-specific defenses. Chương 7 phân tích các công trình tiêu biểu được tutorial đề cập. Chương ?? mô tả demo, thiết lập thực nghiệm, kết quả và phân tích lỗi. Chương ?? thảo luận các hạn chế, safety-utility trade-off, attack-defense arms race và hướng nghiên cứu tương lai. Cuối cùng, Chương ?? tổng kết các nội dung chính của báo cáo.

2 Kiến thức nền

Chương này trình bày các khái niệm nền tảng cần thiết để phân tích jailbreak attacks, jailbreak defenses và phương pháp đánh giá độ an toàn của các mô hình ngôn ngữ lớn. Nội dung tập trung vào cách LLM sinh phản hồi, quá trình căn chỉnh mô hình, thứ bậc chỉ dẫn, threat model, các khái niệm an toàn liên quan và sự khác biệt giữa chatbot với agentic systems.

2.1 Mô hình ngôn ngữ lớn

Mô hình ngôn ngữ lớn (Large Language Model – LLM) là mô hình học máy được huấn luyện trên lượng lớn dữ liệu văn bản để học phân phối xác suất của ngôn ngữ. Với một chuỗi token đầu vào

$$x = (x_1, x_2, \dots, x_n), \quad (4)$$

mô hình tự hồi quy ước lượng xác suất của token tiếp theo dựa trên các token đã xuất hiện trước đó:

$$P_\theta(x_{n+1} \mid x_1, x_2, \dots, x_n), \quad (5)$$

trong đó θ là tập tham số đã học của mô hình. Trong quá trình suy luận, mô hình sinh phản hồi bằng cách dự đoán token kế tiếp, đưa token vừa sinh trở lại ngữ cảnh, rồi tiếp tục quá trình này cho đến khi hoàn thành phản hồi.

Trước khi được đưa vào mô hình, văn bản được chuyển thành chuỗi token thông qua tokenizer. Nếu s là chuỗi văn bản ban đầu và τ là tokenizer, quá trình mã hóa có thể được biểu diễn bởi

$$(x_1, x_2, \dots, x_n) = \tau(s). \quad (6)$$

Tokenization có vai trò quan trọng trong nghiên cứu jailbreak. Hai chuỗi văn bản nhìn giống nhau đối với con người có thể tạo ra chuỗi token khác nhau đối với mô hình. Ngược lại, một chuỗi token không tự nhiên hoặc khó đọc vẫn có thể làm thay đổi mạnh hành vi của mô hình. Điều này là một cơ sở cho các phương pháp tối ưu adversarial suffix, chẳng hạn Greedy Coordinate Gradient (GCG) [2].

Phần lớn LLM hiện đại được xây dựng dựa trên kiến trúc Transformer. Trong phạm vi báo cáo này, chi tiết kiến trúc không phải trọng tâm chính. Điểm quan trọng là LLM xử lý system prompt, chỉ dẫn của người dùng, lịch sử hội thoại và dữ liệu bổ sung trong cùng một context window. Vì vậy, khi các nguồn thông tin này chứa chỉ dẫn xung đột, mô hình phải dựa vào quá trình căn chỉnh đã học để xác định hành vi phù hợp, thay vì có một cơ chế bảo mật hình thức tuyệt đối.

2.2 Instruction tuning và safety alignment

Một LLM được triển khai cho người dùng thường trải qua nhiều giai đoạn huấn luyện và căn chỉnh. Các giai đoạn cụ thể có thể khác nhau giữa từng hệ thống, nhưng thường gồm pretraining, supervised fine-tuning, preference alignment và safety alignment.

Trong giai đoạn **pretraining**, mô hình học dự đoán token tiếp theo trên tập dữ liệu văn bản lớn. Giai đoạn này giúp mô hình học cấu trúc ngôn ngữ, kiến thức tổng quát và nhiều mẫu suy luận xuất hiện trong dữ liệu. Tuy nhiên, pretraining không trực tiếp bảo đảm mô hình sẽ làm theo chỉ dẫn hoặc tuân thủ chính sách an toàn.

Trong giai đoạn **supervised fine-tuning** (SFT), mô hình được huấn luyện trên các cặp dữ liệu gồm instruction và phản hồi mẫu:

$$\mathcal{D}_{\text{SFT}} = \left\{ (x^{(i)}, y^{(i)}) \right\}_{i=1}^N, \quad (7)$$

trong đó $x^{(i)}$ là chỉ dẫn và $y^{(i)}$ là phản hồi mong muốn. SFT giúp mô hình học cách phản hồi theo định dạng hội thoại, làm theo yêu cầu và xử lý một số tình huống phổ biến.

Trong giai đoạn **preference alignment**, mô hình được điều chỉnh dựa trên thông tin về phản hồi nào được ưu tiên hơn. Một mẫu dữ liệu preference có thể có dạng

$$(x, y^+, y^-), \quad (8)$$

trong đó y^+ là phản hồi được ưu tiên và y^- là phản hồi kém phù hợp hơn. Reinforcement Learning from Human Feedback (RLHF) và các phương pháp preference optimization trực tiếp đều thuộc nhóm kỹ thuật này.

Safety alignment là quá trình điều chỉnh mô hình để nhận diện và xử lý các yêu cầu có rủi ro. Mô hình được kỳ vọng từ chối yêu cầu không được phép, cung cấp thông tin ở mức an toàn khi có thể, tránh tiết lộ chỉ dẫn nội bộ và chuyển hướng sang nội dung phù hợp hơn. Tuy nhiên, safety alignment không tạo ra bảo đảm tuyệt đối, vì không gian đầu vào ngôn ngữ rất lớn trong khi dữ liệu căn chỉnh chỉ bao phủ một phần hữu hạn các tình huống có thể xảy ra.


Chính khoảng cách giữa những mẫu đã được căn chỉnh trong huấn luyện và những biến thể đầu vào xuất hiện tại thời điểm suy luận là một trong các nguyên nhân khiến jailbreak vẫn tồn tại.

2.3 Thứ bậc chỉ dẫn trong hệ thống LLM

Ứng dụng LLM thường kết hợp nhiều loại thông tin trong cùng một ngữ cảnh. Có thể phân biệt bốn nguồn chính:

1. **System instruction:** chỉ dẫn cấp hệ thống, quy định vai trò, chính sách và giới hạn tổng quát;
2. **Application instruction:** chỉ dẫn do nhà phát triển ứng dụng thiết lập;
3. **User instruction:** yêu cầu trực tiếp của người dùng;
4. **External content:** nội dung từ website, tài liệu, email, cơ sở dữ liệu hoặc kết quả trả về từ công cụ.

Về nguyên tắc, chỉ dẫn có độ ưu tiên cao hơn phải chi phối chỉ dẫn có độ ưu tiên thấp hơn. Đồng thời, dữ liệu bên ngoài cần được xem là dữ liệu để xử lý, không mặc định là chỉ dẫn điều khiển hệ thống.



Hình 1: Thứ bậc chỉ dẫn và vị trí của nội dung bên ngoài trong ứng dụng LLM.

Trong thực tế, LLM xử lý các nguồn trên dưới dạng token trong cùng một context window. Mô hình không có một bộ phân tích cú pháp bảo mật tuyệt đối để phân biệt instruction với data. Vì vậy, nội dung bên ngoài có thể chứa câu lệnh làm mô hình hiểu sai vai trò của dữ liệu. Đây là nền tảng của prompt injection, đặc biệt là indirect prompt injection trong các hệ thống retrieval và tool-integrated agents.

2.4 Threat model trong nghiên cứu jailbreak

Threat model mô tả mục tiêu, quyền truy cập, kiến thức và giới hạn của kẻ tấn công. Việc xác định threat model là cần thiết vì hai phương pháp jailbreak không thể được so sánh công bằng nếu chúng dựa trên các giả định khác nhau.

Bảng 1 tổng hợp các chiều thường được sử dụng trong nghiên cứu jailbreak.

Bảng 1: Các chiều chính của threat model trong nghiên cứu jailbreak.

Chiều đánh giá	Các trường hợp phổ biến	Ý nghĩa
Quyền truy cập	White-box, gray-box, black-box	Attacker có thể truy cập tham số, gradient, logit hoặc chỉ giao tiếp qua đầu vào–đầu ra.
Số lượt tương tác	Single-turn, multi-turn	Attack được thực hiện trong một truy vấn hoặc qua nhiều lượt hội thoại.
Khả năng thích nghi	Static, adaptive	Attacker có thay đổi chiến lược dựa trên phản hồi hoặc defense hay không.
Ngân sách truy vấn	Giới hạn hoặc không giới hạn	Phản ánh chi phí và tính khả thi của attack, đặc biệt trong black-box setting.
Kiến thức về hệ thống	Không biết, biết một phần, biết đầy đủ	Attacker có biết model family, system prompt, policy hoặc defense đang được sử dụng hay không.
Mức tự động hóa	Manual, template-based, optimization-based	Xác định mức độ phụ thuộc vào con người và thuật toán tìm kiếm.
Mục tiêu	Unsafe response, policy bypass, tool misuse	Hành vi mà attacker muốn hệ thống thực hiện.
Đối tượng	Chatbot, multimodal model, agent, robot	Quyết định phạm vi hậu quả và loại evaluator cần sử dụng.
Transferability	Model-specific, transferable	Attack chỉ hiệu quả trên một mô hình hay có thể chuyển sang mô hình khác.

Trong các chương sau, các chiều này được dùng để phân loại những nhóm tấn công khác nhau. Ví dụ, white-box attacks có thể tận dụng thông tin nội bộ của mô hình để tối ưu đầu vào, trong khi black-box attacks chỉ dựa trên việc gửi prompt và quan sát phản hồi. Tương tự, adaptive attacks thường khó phòng thủ hơn static attacks vì attacker có thể điều chỉnh chiến lược dựa trên cơ chế defense.

2.5 Phân biệt các khái niệm an toàn liên quan

Các thuật ngữ jailbreaking, prompt injection, adversarial example, data poisoning và backdoor thường được sử dụng gần nhau nhưng mô tả các threat model khác nhau. Việc phân biệt các khái niệm này giúp xác định đúng phạm vi của báo cáo.

Bảng 2: Phân biệt jailbreaking với các khái niệm an toàn liên quan.

Khái niệm	Thời điểm tác động	Mục tiêu chính	Ví dụ bề mặt tác động
Jailbreaking	Thời điểm suy luận	Vượt qua ràng buộc an toàn của mô hình	User prompt, suffix hoặc hội thoại nhiều lượt
Prompt injection	Thời điểm suy luận	Thay đổi luồng điều khiển hoặc thứ tự ưu tiên chỉ dẫn	User prompt hoặc dữ liệu được đưa vào context
Indirect prompt injection	Thời điểm suy luận	Làm agent chịu ảnh hưởng bởi chỉ dẫn nằm trong nguồn dữ liệu ngoài	Website, email, tài liệu hoặc tool output
Adversarial example	Thời điểm suy luận	Làm mô hình dự đoán hoặc hành xử sai dưới nhiều có chủ đích	Token, hình ảnh, âm thanh hoặc embedding
Data poisoning	Giai đoạn huấn luyện	Làm thay đổi hành vi mô hình thông qua dữ liệu bị nhiễm	Pretraining corpus hoặc fine-tuning dataset
Backdoor	Huấn luyện hoặc chỉnh sửa mô hình	Kích hoạt hành vi ẩn khi xuất hiện trigger	Trigger token, mẫu văn bản hoặc đặc trưng đầu vào

Jailbreaking chủ yếu nhằm làm mô hình vi phạm chính sách an toàn. Prompt injection tập trung vào việc khiến ứng dụng bỏ qua hoặc thay đổi chỉ dẫn ban đầu. Trong chatbot đơn giản, hai khái niệm này có thể giao nhau. Trong agentic system, prompt injection có thể không yêu cầu mô hình tạo nội dung không an toàn, mà chỉ cần làm agent thực hiện một công cụ, truy xuất dữ liệu hoặc thay đổi kế hoạch ngoài ý định của người dùng.

2.6 Safety–utility trade-off

Một hệ thống an toàn không chỉ cần giảm phản hồi không phù hợp mà còn phải duy trì khả năng hỗ trợ các yêu cầu hợp lệ. Nếu chỉ tối ưu để mô hình từ chối càng nhiều càng tốt, hệ thống có thể đạt tỷ lệ unsafe compliance thấp nhưng gần như không còn giá trị sử dụng.

Có thể phân biệt hai lỗi quan trọng:

1. **Unsafe compliance:** mô hình chấp nhận hoặc thực hiện yêu cầu không an toàn. Đây là kết quả mà jailbreak attack thường hướng tới.
2. **Over-refusal:** mô hình từ chối một yêu cầu hợp lệ. Đây là tác dụng phụ thường gặp khi defense quá thận trọng.

Vì vậy, đánh giá một defense không nên chỉ dựa trên Attack Success Rate. Một phương pháp phòng thủ đầy đủ cần được kiểm tra trên cả tập harmful prompts để đánh giá safety và tập benign prompts để đánh giá utility. Ngoài ra, cần xem xét chi phí suy luận, độ trễ, số lần gọi mô hình và khả năng chống lại adaptive attacker.

Sự đánh đổi giữa safety và utility là một chủ đề xuyên suốt của báo cáo: defense quá yếu làm tăng rủi ro jailbreak, trong khi defense quá nghiêm ngặt làm tăng over-refusal và làm giảm trải nghiệm người dùng.

2.7 Từ chatbot đến agentic systems

Chatbot dựa trên LLM thường nhận yêu cầu và trả về văn bản. Agentic system mở rộng mô hình này bằng cách bổ sung các thành phần như bộ nhớ, bộ lập kế hoạch, retrieval từ nguồn dữ liệu bên ngoài, khả năng gọi công cụ, quan sát trạng thái môi trường và vòng lặp hành động-phản hồi.

Có thể biểu diễn một trajectory của agent dưới dạng

$$\tau = (o_0, a_0, o_1, a_1, \dots, o_T), \quad (9)$$

trong đó o_t là observation tại thời điểm t và a_t là hành động được agent lựa chọn.

Đối với chatbot, evaluator thường tập trung vào phản hồi cuối. Đối với agentic system, đánh giá cần xem xét cả trajectory, bao gồm kế hoạch, lời gọi công cụ, trạng thái trung gian và hành động cuối cùng. Một agent có thể tạo ra phản hồi văn bản an toàn nhưng vẫn thực hiện lời gọi công cụ không phù hợp ở bước trung gian. Ngược lại, một kế hoạch không an toàn có thể bị action controller chặn trước khi hành động được thực thi.

Bảng 3: So sánh bề mặt an toàn của chatbot và agentic system.

Khía cạnh	Chatbot	Agentic system
Đầu vào	User prompt và lịch sử hội thoại	User prompt, memory, retrieval, tool output và environment
Đầu ra	Chủ yếu là văn bản	Văn bản, kế hoạch, lời gọi công cụ và hành động
Đơn vị đánh giá	Một phản hồi hoặc một hội thoại	Toàn bộ trajectory của agent
Bề mặt tấn công	Jailbreak và direct prompt injection	Jailbreak, indirect injection, memory poisoning và tool manipulation
Hậu quả	Nội dung phản hồi không phù hợp	Có thể ảnh hưởng dữ liệu, dịch vụ hoặc môi trường vật lý
Phòng thủ	Input/output guard và alignment	Guard, sandbox, permission control, monitoring và human confirmation

Sự mở rộng từ chatbot sang agentic systems là lý do báo cáo không chỉ phân tích jailbreak trên LLM sinh văn bản, mà còn xem xét các hệ thống có khả năng sử dụng công cụ và thực hiện hành động. Với các hệ thống này, an toàn không thể chỉ phụ thuộc vào hành vi từ chối của mô hình, mà cần được thiết kế ở cấp kiến trúc.

3 Jailbreak Attacks

Chương này hệ thống hóa các nhóm phương pháp jailbreak đối với mô hình ngôn ngữ lớn đã được căn chỉnh an toàn. Mục tiêu của chương không phải là cung cấp hướng dẫn tạo nội dung gây hại, mà là phân tích các cơ chế tấn công ở mức khái niệm để phục vụ đánh giá an toàn và thiết kế phòng thủ. Các phương pháp được phân loại theo quyền truy cập của attacker, số lượt tương tác, mức độ tự động hóa, khả năng chuyển giao và khả năng thích nghi trước defense.

3.1 Taxonomy các phương pháp jailbreak

Jailbreak attack là quá trình xây dựng hoặc tối ưu đầu vào nhằm khiến mô hình tạo ra phản hồi không phù hợp với chính sách an toàn. Xét một yêu cầu gốc x thuộc nhóm không được phép, attacker tìm một biến đổi $\mathcal{T}$ để tạo ra đầu vào mới

$$x' = \mathcal{T}(x), \quad (10)$$

trong đó x' vẫn giữ mục tiêu ngữ nghĩa của x nhưng làm suy yếu hành vi từ chối của mô hình. Mục tiêu khái quát của attack có thể được biểu diễn là

$$F_{\theta}(x', s, c) \notin \mathcal{Y}_{\text{safe}}, \quad (11)$$

trong đó F_{θ} là mô hình, s là system instruction, c là ngữ cảnh bổ sung và $\mathcal{Y}_{\text{safe}}$ là tập phản hồi phù hợp với chính sách an toàn.

Chương 2 đã trình bày threat model của jailbreak theo các chiều như quyền truy cập, số lượt tương tác, ngân sách truy vấn, mức độ hiểu biết của attacker và khả năng thích nghi. Dựa trên nền tảng đó, chương này tập trung vào cách các jailbreak attacks được xây dựng trong thực tế, tức là phân loại theo cơ chế tạo hoặc tối ưu đầu vào.

Bảng 4 tóm tắt các nhóm phương pháp jailbreak được phân tích trong chương này.

Bảng 4: Các nhóm phương pháp jailbreak được phân tích trong chương này.

Nhóm pháp	phương	Cơ chế chính	Đặc điểm tiêu biểu
Manual jailbreak		Viết lại yêu cầu bằng bối cảnh, vai trò hoặc cách diễn đạt khác	Đơn giản, không cần truy cập nội bộ mô hình, nhưng phụ thuộc nhiều vào kinh nghiệm của người thiết kế.
Template-based attack		Sử dụng một mẫu prompt cố định rồi thay thế nội dung mục tiêu	Dễ mở rộng trên nhiều yêu cầu, nhưng dễ bị nhận diện nếu template quá cố định.
Obfuscation và encoding		Biến đổi hình thức bề mặt của đầu vào nhưng vẫn giữ mục tiêu ngữ nghĩa	Khai thác hạn chế của bộ lọc từ khóa, classifier hoặc các mẫu từ chối dựa trên đặc trưng bề mặt.
Multi-turn jailbreak		Dẫn dắt mô hình qua nhiều lượt hội thoại thay vì yêu cầu trực tiếp	Rủi ro tích lũy theo ngữ cảnh, khó đánh giá nếu chỉ xét từng lượt riêng lẻ.
White-box optimization		Tối ưu chuỗi token hoặc adversarial suffix dựa trên thông tin nội bộ của mô hình	Hữu ích để nghiên cứu giới hạn của safety alignment, nhưng giả định quyền truy cập mạnh.
Black-box automated jailbreak		Tự động sinh, đánh giá và tinh chỉnh prompt thông qua phản hồi của target model	Phù hợp với bối cảnh dịch vụ đóng, nhưng phụ thuộc vào ngân sách truy vấn và chất lượng evaluator.
Transferable attack		Tạo attack trên một mô hình hoặc tập yêu cầu rồi chuyển sang mục tiêu khác	Cho thấy các mô hình khác nhau có thể chia sẻ điểm yếu trong cơ chế từ chối.
Adaptive attack		Điều chỉnh chiến lược dựa trên defense hoặc phản hồi của hệ thống	Quan trọng khi đánh giá độ bền của defense trong điều kiện attacker có khả năng thích nghi.

Taxonomy này cho thấy jailbreak không phải một kỹ thuật đơn lẻ mà là một nhóm rộng các chiến lược tấn công. Một attack có thể đồng thời thuộc nhiều nhóm, chẳng hạn black-box, multi-turn, automated và adaptive.

3.2 Manual và template-based attacks

Các jailbreak đầu tiên thường được xây dựng thủ công. Attacker viết lại yêu cầu ban đầu bằng cách thay đổi vai trò, bối cảnh hoặc hình thức chỉ dẫn nhằm làm mô hình hiểu sai ý định an toàn. Những attack này thường dựa trên khả năng khai thác sự không nhất quán giữa helpfulness và refusal: mô hình được huấn luyện để hỗ trợ người dùng, nhưng đồng thời phải tuân thủ giới hạn an toàn.

Manual jailbreak có thể sử dụng nhiều chiến lược ở mức khái niệm, chẳng hạn:

- thay đổi bối cảnh để làm yêu cầu trông giống một tình huống giả định hoặc phân tích học thuật;
- yêu cầu mô hình nhập vai vào một vai trò không bị ràng buộc bởi chính sách thông thường;
- chia nhỏ mục tiêu thành nhiều phần để làm giảm khả năng phát hiện của bộ lọc;
- diễn đạt lại yêu cầu sao cho mô hình tập trung vào tính hữu ích thay vì nhận diện rủi ro.

Template-based attack tổng quát hóa manual attack bằng cách sử dụng một mẫu prompt có thể áp dụng cho nhiều yêu cầu khác nhau. Thay vì thiết kế lại toàn bộ prompt cho từng mục tiêu, attacker chỉ thay thế một số trường trong template, chẳng hạn loại nhiệm vụ, bối cảnh hoặc nội dung cần kiểm thử. Cách này giúp mở rộng attack nhanh hơn nhưng thường kém bền vững, vì template cố định dễ bị nhận diện bởi các mô hình hoặc bộ lọc an toàn.

Ưu điểm của manual và template-based attacks là đơn giản, không yêu cầu truy cập vào mô hình và dễ triển khai trong black-box setting. Tuy nhiên, chúng thường phụ thuộc nhiều vào kinh nghiệm của người thiết kế, dễ bị lỗi thời khi mô hình được cập nhật và có khả năng chuyển giao không ổn định.

3.3 Obfuscation và encoding attacks

Obfuscation attack tìm cách thay đổi hình thức bề mặt của đầu vào mà vẫn giữ lại mục tiêu ngữ nghĩa. Ý tưởng chính là làm cho yêu cầu trở nên khó nhận diện hơn đối với các bộ lọc dựa trên từ khóa, classifier hoặc các mẫu từ chối đã học trong quá trình safety alignment.

Các biến đổi thường gặp ở mức khái niệm bao gồm:

- thay đổi chính tả, dấu câu hoặc cách phân tách từ;
- dùng ký hiệu, mã hóa hoặc biểu diễn trung gian;

- diễn đạt vòng vo thay vì nêu trực tiếp mục tiêu;
- sử dụng nhiều ngôn ngữ hoặc trộn các hệ chữ viết;
- tách một yêu cầu thành nhiều mảnh ngữ nghĩa rời rạc.

Những attack này khai thác khoảng cách giữa cách con người hiểu nội dung và cách mô hình hoặc guard model biểu diễn nội dung dưới dạng token. Nếu bộ lọc an toàn phụ thuộc quá nhiều vào đặc trưng bề mặt, một biến đổi nhỏ có thể làm giảm khả năng phát hiện. Tuy nhiên, obfuscation không bảo đảm thành công nếu hệ thống có cơ chế chuẩn hóa đầu vào, semantic filtering hoặc đánh giá dựa trên toàn bộ ngữ cảnh.

Trong báo cáo này, obfuscation được xem là một nhóm attack quan trọng vì nó cho thấy phòng thủ ở mức từ khóa hoặc mẫu cố định thường không đủ. Một defense hiệu quả cần đánh giá ý định ngữ nghĩa của yêu cầu, không chỉ dựa trên hình thức bề mặt của prompt.

3.4 Multi-turn jailbreak

Single-turn jailbreak cố gắng vượt qua cơ chế an toàn trong một truy vấn duy nhất. Ngược lại, multi-turn jailbreak xây dựng attack qua nhiều lượt hội thoại. Thay vì yêu cầu trực tiếp mục tiêu cuối cùng, attacker có thể dẫn dắt mô hình qua một chuỗi câu hỏi trung gian, làm cho ngữ cảnh hội thoại dần dịch chuyển về phía hành vi không mong muốn.

Một hội thoại multi-turn có thể được biểu diễn bởi chuỗi

$$h_t = (u_1, y_1, u_2, y_2, \dots, u_t), \quad (12)$$

trong đó u_i là lượt người dùng và y_i là phản hồi của mô hình. Ở mỗi lượt, phản hồi tiếp theo phụ thuộc không chỉ vào yêu cầu hiện tại mà còn vào lịch sử hội thoại:

$$y_t = F_\theta(h_t, s, c). \quad (13)$$

Multi-turn jailbreak khó đánh giá hơn single-turn vì rủi ro có thể không nằm trong từng lượt riêng lẻ mà xuất hiện từ sự tích lũy ngữ cảnh. Một câu hỏi trung gian có thể trông hợp lệ khi xét độc lập, nhưng khi kết hợp với các lượt trước đó lại phục vụ cho mục tiêu không an toàn.

Nhóm attack này đặc biệt quan trọng đối với agentic systems. Agent thường có bộ nhớ, kế hoạch và trạng thái trung gian; do đó attacker có thể tác động từng bước đến quá trình ra quyết định thay vì chỉ tấn công phản hồi cuối cùng. Đây là lý do evaluation cho agent cần xem xét toàn bộ trajectory thay vì chỉ kiểm tra output cuối.

3.5 White-box optimization

Trong thiết lập white-box, attacker có quyền truy cập vào một phần thông tin nội bộ của mô hình, chẳng hạn tham số, gradient hoặc logit. Khi đó, jailbreak có thể được mô hình hóa như một bài toán tối ưu đầu vào. Một hướng tiêu biểu là tìm adversarial suffix a để nối vào yêu cầu gốc x :

$$x' = x \oplus a, \quad (14)$$

trong đó $\oplus$ là phép nối chuỗi. Mục tiêu là tìm suffix làm tăng xác suất mô hình tạo phản hồi thuộc dạng mà attacker mong muốn. Bài toán tổng quát có thể viết dưới dạng

$$a^* = \arg \min_{a \in \mathcal{V}^m} \mathcal{L}(F_\theta(x \oplus a)), \quad (15)$$

trong đó $\mathcal{V}$ là vocabulary, m là độ dài suffix và $\mathcal{L}$ là hàm mất mát được thiết kế để hướng mô hình đến một dạng đầu ra nhất định.

Công trình Universal and Transferable Adversarial Attacks on Aligned Language Models đề xuất cách tối ưu adversarial suffix bằng kết hợp tìm kiếm greedy và thông tin gradient, thường được gọi là Greedy Coordinate Gradient (GCG) [2]. Điểm đáng chú ý của hướng này là suffix được tối ưu trên một tập yêu cầu và mô hình có thể chuyển giao một phần sang các mô hình khác.

White-box optimization có ý nghĩa quan trọng về mặt nghiên cứu vì nó cho thấy alignment không chỉ có thể bị phá vỡ bằng prompt thủ công mà còn có thể bị stress test bằng các phương pháp tối ưu có hệ thống. Tuy nhiên, thiết lập white-box thường ít phù hợp hơn với các dịch vụ thương mại đóng, nơi attacker không có quyền truy cập gradient hoặc tham số mô hình.

3.6 Black-box automated jailbreak

Trong thiết lập black-box, attacker chỉ có thể gửi prompt và quan sát phản hồi. Không có gradient trực tiếp để tối ưu đầu vào. Vì vậy, black-box automated jailbreak thường sử dụng một vòng lặp gồm ba thành phần: một bộ sinh prompt, một target model và một bộ đánh giá mức độ thành công.

Quy trình tổng quát có thể mô tả như sau:

1. sinh một candidate prompt dựa trên mục tiêu kiểm thử;
2. gửi candidate prompt đến target model;
3. đánh giá phản hồi của target model;
4. cập nhật candidate prompt dựa trên kết quả đánh giá;

5. lặp lại cho đến khi đạt tiêu chí dừng hoặc hết ngân sách truy vấn.

PAIR là một ví dụ tiêu biểu của black-box automated jailbreak [3]. Phương pháp này sử dụng một attacker LLM để tự động sinh và điều chỉnh prompt qua nhiều vòng tương tác với target model. Thay vì dựa hoàn toàn vào prompt thủ công, PAIR xem jailbreak như một quá trình refinement lặp lại dựa trên phản hồi quan sát được.

TAP mở rộng hướng này bằng cấu trúc tìm kiếm dạng cây và cơ chế pruning [5]. Thay vì chỉ theo một nhánh refinement, TAP duy trì nhiều candidate prompts, đánh giá sơ bộ và loại bỏ những nhánh ít có khả năng thành công trước khi gửi đến target model. Cách này giúp giảm số truy vấn không cần thiết và cải thiện hiệu quả tìm kiếm trong black-box setting.

Các phương pháp black-box automated jailbreak phản ánh bối cảnh thực tế hơn white-box attack, vì nhiều hệ thống triển khai chỉ cho phép người dùng gửi truy vấn và nhận phản hồi. Tuy nhiên, chúng cũng đặt ra thách thức lớn cho evaluation: kết quả phụ thuộc vào ngân sách truy vấn, chất lượng của attacker model, chất lượng của judge và chính sách dừng.

3.7 Transferability

Transferability là khả năng một jailbreak được tạo trên một mô hình hoặc một tập yêu cầu vẫn có hiệu quả trên mô hình hoặc yêu cầu khác. Đây là một thuộc tính quan trọng vì attacker không phải lúc nào cũng có quyền truy cập vào target model thật. Thay vào đó, attacker có thể tối ưu attack trên một surrogate model rồi thử chuyển sang target model.

Có thể phân biệt ba dạng transferability:

1. **Cross-prompt transfer:** một prompt hoặc suffix có hiệu quả trên nhiều yêu cầu khác nhau;
2. **Cross-model transfer:** attack được tạo trên một mô hình nhưng vẫn có tác dụng trên mô hình khác;
3. **Cross-defense transfer:** attack vẫn có hiệu quả khi hệ thống bổ sung một số lớp phòng thủ.

Về mặt nghiên cứu, transferability cho thấy các mô hình khác nhau có thể chia sẻ những điểm yếu tương tự trong cách học hành vi từ chối. Nếu một attack chỉ hoạt động trên một target duy nhất, nó có thể phản ánh đặc điểm riêng của mô hình đó. Ngược lại, nếu attack chuyển giao qua nhiều mô hình, nó gợi ý rằng vấn đề có thể nằm ở cơ chế alignment hoặc dữ liệu căn chỉnh chung.

Transferability cũng làm tăng mức độ nghiêm trọng của jailbreak. Một attack có tính chuyển giao cao có thể được phát triển trên mô hình mở hoặc mô hình nhỏ hơn,

sau đó áp dụng vào hệ thống đóng mà attacker không hiểu đầy đủ. Vì vậy, benchmark jailbreak thường cần đánh giá cả model-specific success và transfer success.

3.8 Adaptive attacks

Static attack sử dụng một prompt hoặc chiến lược cố định, không thay đổi theo defense. Ngược lại, adaptive attack giả định attacker biết hoặc suy đoán cơ chế phòng thủ và điều chỉnh attack để vượt qua chính cơ chế đó. Sự khác biệt này rất quan trọng khi đánh giá độ bền vững của defense.

Một defense có thể hoạt động tốt trước static attacks nhưng suy giảm mạnh khi attacker thích nghi. Ví dụ, nếu hệ thống chỉ chặn một số mẫu bề mặt, attacker có thể thay đổi cách diễn đạt. Nếu hệ thống sử dụng judge hoặc guard model, attacker có thể tối ưu prompt để vừa vượt qua guard vừa làm target model phản hồi không an toàn. Nếu hệ thống dùng nhiều lần kiểm tra ở thời điểm suy luận, attacker có thể tìm những đầu vào tạo phản hồi ổn định hơn qua các biến thể.

Có thể biểu diễn adaptive attack như một quá trình tối ưu phụ thuộc vào defense D :

$$x^* = \arg \max_{x' \in \mathcal{X}} A(D(F_\theta(x'))), \quad (16)$$

trong đó A là hàm đánh giá mức độ thành công của attack. Công thức này chỉ mang tính khái quát, nhưng cho thấy attacker không chỉ tối ưu đối với mô hình F_θ mà còn tối ưu đối với toàn bộ pipeline có defense.

Adaptive attacks làm rõ một nguyên tắc quan trọng: đánh giá defense chỉ trên một tập attack cố định thường chưa đủ. Một defense mạnh cần được kiểm tra trong điều kiện attacker có khả năng quan sát, phản hồi và thay đổi chiến lược. Đây là lý do các chương sau sẽ phân tích defense không chỉ theo Attack Success Rate, mà còn theo over-refusal, chi phí suy luận và khả năng chống lại attacker thích nghi.

3.9 Tổng kết chương

Chương này đã hệ thống hóa các nhóm jailbreak attacks theo nhiều chiều: manual và template-based attacks, obfuscation và encoding attacks, multi-turn attacks, white-box optimization, black-box automated jailbreak, transferability và adaptive attacks. Các nhóm này khác nhau về giả định quyền truy cập, chi phí truy vấn, mức tự động hóa và khả năng chuyển giao.

Một điểm chung giữa các phương pháp là chúng đều khai thác khoảng cách giữa mục tiêu safety alignment và sự đa dạng gần như không giới hạn của đầu vào ngôn ngữ tự nhiên. Manual attacks cho thấy mô hình có thể bị ảnh hưởng bởi cách diễn đạt và bối cảnh. Optimization-based attacks cho thấy có thể tìm đầu vào bất thường bằng thuật

toán. Black-box automated attacks cho thấy quá trình jailbreak có thể được tự động hóa ngay cả khi không truy cập tham số mô hình. Multi-turn và adaptive attacks tiếp tục mở rộng bề mặt rủi ro khi hệ thống có trạng thái, bộ nhớ, công cụ hoặc defense phức tạp.

Các kết quả này dẫn đến nhu cầu nghiên cứu phòng thủ theo nhiều lớp. Chương tiếp theo phân tích các nhóm jailbreak defenses, bao gồm input filtering, adversarial training, inference-time defenses, output moderation, guard models và defense-in-depth.

4 Jailbreak Defenses

Chương trước đã trình bày các nhóm jailbreak attacks và cho thấy rằng attack có thể được xây dựng thủ công, tự động hóa, tối ưu bằng thuật toán hoặc thích nghi với cơ chế phòng thủ. Chương này phân tích các nhóm phòng thủ trước jailbreak ở cấp đầu vào, cấp mô hình, thời điểm suy luận, đầu ra và toàn bộ kiến trúc hệ thống.

Mục tiêu của jailbreak defense không chỉ là giảm tỷ lệ mô hình tạo phản hồi không an toàn, mà còn phải duy trì khả năng hỗ trợ các yêu cầu hợp lệ. Do đó, một defense cần được đánh giá đồng thời theo safety, utility, over-refusal, chi phí suy luận và khả năng chống lại adaptive attacks.

4.1 Taxonomy các phương pháp phòng thủ

Có thể phân loại jailbreak defenses theo vị trí triển khai trong pipeline của hệ thống LLM. Bảng 5 tóm tắt các nhóm phòng thủ chính được phân tích trong chương này.

Bảng 5: Taxonomy các phương pháp phòng thủ trước jailbreak.

Nhóm phòng thủ	Vị trí triển khai	Mục tiêu chính
Input filtering	Trước khi prompt được đưa vào mô hình	Phát hiện hoặc chặn đầu vào có rủi ro, bao gồm prompt bất thường hoặc có dấu hiệu jailbreak.
Prompt preprocessing	Trước hoặc trong quá trình xây dựng context	Chuẩn hóa, làm sạch hoặc tái diễn đạt đầu vào để giảm tác động của obfuscation và prompt injection.
Adversarial training	Trong quá trình huấn luyện hoặc fine-tuning	Bổ sung dữ liệu tấn công vào huấn luyện để tăng độ bền của hành vi từ chối.
Inference-time defenses	Trong quá trình suy luận	Kiểm tra tính ổn định của phản hồi, lấy mẫu nhiều lần hoặc dùng cơ chế phát hiện rủi ro tại runtime.
Output moderation	Sau khi mô hình sinh phản hồi	Kiểm duyệt phản hồi trước khi gửi cho người dùng.
Guard models	Xung quanh mô hình chính	Dùng một mô hình hoặc classifier riêng để đánh giá input, output hoặc trajectory.
System-level defenses	Cấp ứng dụng và kiến trúc	Giới hạn quyền công cụ, sandbox, xác nhận người dùng và monitoring.
Defense-in-depth	Toàn bộ pipeline	Kết hợp nhiều lớp phòng thủ để tránh phụ thuộc vào một cơ chế duy nhất.

Cách phân loại này nhấn mạnh rằng defense không nhất thiết nằm bên trong LLM. Trong các hệ thống thực tế, độ an toàn thường phụ thuộc vào nhiều thành phần phối hợp: policy, guard model, system prompt, mô hình chính, bộ điều khiển công cụ, kiểm duyệt đầu ra và giám sát sau triển khai.

4.2 Input filtering

Input filtering là lớp phòng thủ được đặt trước mô hình chính. Mục tiêu là phát hiện hoặc chặn các prompt có dấu hiệu rủi ro trước khi chúng được đưa vào LLM. Các bộ lọc đầu vào có thể dựa trên luật, từ khóa, classifier, embedding similarity hoặc một guard model chuyên đánh giá an toàn.

Một input filter đơn giản có thể kiểm tra xem yêu cầu có thuộc nhóm chính sách không được phép hay không. Các hệ thống phức tạp hơn có thể đánh giá cả ý định ngữ nghĩa, mức độ bất thường của prompt, dấu hiệu obfuscation hoặc các chỉ dẫn cố gắng thay đổi vai trò của mô hình.

Ưu điểm của input filtering là có thể ngăn một số attack ngay từ đầu, giảm tải cho mô hình chính và dễ tích hợp vào pipeline triển khai. Tuy nhiên, input filtering có ba hạn chế quan trọng. Thứ nhất, nếu bộ lọc dựa quá nhiều vào đặc trưng bề mặt, attacker có thể thay đổi cách diễn đạt để né lọc. Thứ hai, bộ lọc quá nghiêm ngặt có thể làm tăng over-refusal. Thứ ba, input filtering khó xử lý các trường hợp multi-turn hoặc indirect prompt injection, nơi rủi ro chỉ xuất hiện khi kết hợp nhiều phần ngữ cảnh.

Do đó, input filtering nên được xem là một lớp phòng thủ ban đầu, không phải cơ chế bảo vệ duy nhất.

4.3 Prompt preprocessing

Prompt preprocessing là nhóm kỹ thuật xử lý đầu vào trước khi đưa vào mô hình. Mục tiêu là giảm tác động của những biến đổi bề mặt như obfuscation, encoding hoặc cách trình bày gây nhiễu.

Các thao tác preprocessing có thể bao gồm chuẩn hóa ký tự, loại bỏ nhiễu không cần thiết, tách rõ phần instruction và phần data, hoặc chuyển prompt về một định dạng có cấu trúc hơn. Với các hệ thống retrieval hoặc tool-integrated agents, preprocessing còn có thể đánh dấu nội dung bên ngoài là dữ liệu không đáng tin cậy, thay vì cho phép nó được hiểu như chỉ dẫn điều khiển hệ thống.

Một nguyên tắc quan trọng là không trộn lẫn dữ liệu bên ngoài với chỉ dẫn cấp hệ thống. Ví dụ, nội dung từ website, tài liệu, email hoặc kết quả trả về từ công cụ nên được đặt trong vùng ngữ cảnh được đánh dấu rõ là external content. Cách này không loại bỏ hoàn toàn prompt injection, nhưng giúp mô hình và các guard dễ phân biệt hơn giữa instruction và data.

Hạn chế của prompt preprocessing là nó không thể bảo đảm giữ nguyên toàn bộ ý nghĩa của prompt. Nếu preprocessing làm thay đổi nội dung quá mạnh, hệ thống có thể hiểu sai yêu cầu hợp lệ. Ngược lại, nếu preprocessing quá nhẹ, nó có thể không đủ để loại bỏ những biến đổi adversarial.

4.4 Adversarial training

Adversarial training là cách đưa các ví dụ tấn công vào quá trình huấn luyện hoặc fine-tuning để tăng độ bền của mô hình. Thay vì chỉ huấn luyện mô hình trên các yêu cầu thông thường, hệ thống được tiếp xúc thêm với những biến thể jailbreak và học cách phản hồi an toàn.

Một tập dữ liệu adversarial training có thể được biểu diễn dưới dạng

$$\mathcal{D}_{\text{adv}} = \left\{ (x_{\text{adv}}^{(i)}, y_{\text{safe}}^{(i)}) \right\}_{i=1}^N, \quad (17)$$

trong đó $x_{\text{adv}}^{(i)}$ là đầu vào có tính adversarial và $y_{\text{safe}}^{(i)}$ là phản hồi an toàn mong muốn. Mô hình được tối ưu để duy trì hành vi từ chối hoặc chuyển hướng phù hợp trước các biến thể đầu vào này.

Ưu điểm của adversarial training là nó cải thiện trực tiếp hành vi của mô hình, thay vì chỉ đặt thêm một lớp lọc bên ngoài. Nếu tập attack đủ đa dạng, mô hình có thể học được các đặc trưng ngữ nghĩa của yêu cầu không an toàn thay vì chỉ nhận diện mẫu bề mặt.

Tuy nhiên, adversarial training có hai thách thức lớn. Thứ nhất, không gian jailbreak gần như không giới hạn, nên dữ liệu huấn luyện khó bao phủ được mọi biến thể. Thứ hai, nếu huấn luyện quá thiên về từ chối, mô hình có thể tăng over-refusal và làm giảm utility trên yêu cầu hợp lệ. Vì vậy, adversarial training cần đi kèm đánh giá trên cả harmful prompts và benign prompts.

4.5 Inference-time defenses

Inference-time defenses là các phương pháp được áp dụng trong quá trình suy luận, không nhất thiết phải thay đổi tham số của mô hình. Nhóm này đặc biệt hữu ích khi nhà triển khai không có khả năng fine-tune mô hình hoặc muốn bổ sung lớp bảo vệ độc lập với model provider.

Một hướng tiêu biểu là kiểm tra độ ổn định của mô hình trước các biến thể nhỏ của prompt. SmoothLLM dựa trên quan sát rằng một số adversarial prompts có tính giòn trước các thay đổi ký tự nhỏ. Phương pháp này tạo nhiều bản biến đổi của cùng một prompt, truy vấn mô hình trên các bản đó, rồi tổng hợp kết quả để phát hiện đầu vào đáng ngờ [6].

Ở mức khái quát, một inference-time defense dạng smoothing có thể được mô tả như sau. Với prompt đầu vào x , hệ thống tạo ra K biến thể:

$$\tilde{x}_1, \tilde{x}_2, \dots, \tilde{x}_K \sim \mathcal{P}(x), \quad (18)$$

trong đó $\mathcal{P}$ là phân phối biến đổi. Sau đó hệ thống đánh giá các phản hồi tương ứng và đưa ra quyết định cuối cùng bằng hàm tổng hợp:

$$d = g(F_{\theta}(\tilde{x}_1), F_{\theta}(\tilde{x}_2), \dots, F_{\theta}(\tilde{x}_K)). \quad (19)$$

Các biến thể sau này như SemanticSmooth mở rộng ý tưởng smoothing từ biến đổi ký tự sang biến đổi ngữ nghĩa, nhằm tăng độ bền trước các attack không chỉ phụ thuộc vào token-level perturbation [7].

Ưu điểm của inference-time defenses là có thể triển khai mà không cần huấn luyện

lại mô hình chính. Tuy nhiên, chúng thường làm tăng chi phí suy luận vì cần nhiều lần gọi mô hình hoặc guard model. Ngoài ra, nếu attacker biết cơ chế phòng thủ, họ có thể thiết kế adaptive attack để tạo đầu vào ổn định hơn qua các biến thể.

4.6 Output moderation

Output moderation là lớp kiểm tra phản hồi sau khi mô hình đã sinh nội dung nhưng trước khi gửi cho người dùng. Lớp này có thể dùng rule-based filter, classifier hoặc guard model để đánh giá xem phản hồi có vi phạm chính sách hay không.

Output moderation có vai trò quan trọng vì input filtering không phải lúc nào cũng dự đoán được phản hồi cuối cùng. Một prompt ban đầu có thể trông hợp lệ nhưng mô hình lại sinh nội dung không phù hợp; ngược lại, một prompt có dấu hiệu rủi ro có thể vẫn dẫn đến phản hồi an toàn. Do đó, kiểm tra đầu ra giúp giảm rủi ro ở bước cuối của pipeline.

Tuy nhiên, output moderation cũng có hạn chế. Nếu phản hồi đã được sinh đầy đủ, hệ thống đã tiêu tốn chi phí suy luận trước khi phát hiện lỗi. Ngoài ra, nếu output guard quá nghiêm ngặt, nó có thể chặn các phản hồi hợp lệ, đặc biệt trong các ngữ cảnh giáo dục, nghiên cứu, y tế hoặc an toàn công cộng. Vì vậy, output moderation cần phân biệt giữa nội dung gây hại và nội dung phân tích an toàn ở mức phù hợp.

Trong agentic systems, output moderation không nên chỉ kiểm tra văn bản cuối cùng. Hệ thống còn cần kiểm tra các lời gọi công cụ, tham số hành động và trạng thái trung gian, vì rủi ro có thể xảy ra trước khi phản hồi cuối được tạo ra.

4.7 Representation-level defenses

Representation-level defenses cố gắng phát hiện hoặc can thiệp vào các biểu diễn bên trong của mô hình, thay vì chỉ kiểm tra prompt hoặc output ở dạng văn bản. Ý tưởng chung là các yêu cầu có rủi ro hoặc adversarial có thể tạo ra những mẫu kích hoạt khác biệt trong hidden states, attention patterns hoặc embedding space.

Một hướng tiếp cận là huấn luyện classifier trên biểu diễn trung gian của mô hình để phân biệt giữa benign prompts và adversarial prompts. Một hướng khác là can thiệp vào activation để làm giảm khả năng mô hình đi theo hành vi không mong muốn.

Ưu điểm của representation-level defenses là chúng có thể phát hiện những tín hiệu không dễ thấy ở bề mặt văn bản. Tuy nhiên, nhóm phương pháp này thường yêu cầu quyền truy cập sâu vào mô hình, khó áp dụng với API đóng và có thể phụ thuộc mạnh vào kiến trúc cụ thể. Ngoài ra, việc can thiệp vào biểu diễn bên trong có thể ảnh hưởng đến utility nếu không được hiệu chỉnh cẩn thận.

Vì vậy, representation-level defenses phù hợp hơn với bối cảnh nghiên cứu hoặc mô hình mã nguồn mở, trong khi các hệ thống thương mại đóng thường dựa nhiều hơn vào guard model, input/output moderation và system-level controls.

4.8 Guard models

Guard model là một mô hình phụ được dùng để đánh giá mức độ an toàn của input, output hoặc hành động trung gian. Khác với rule-based filter, guard model có thể học biểu diễn ngữ nghĩa phức tạp hơn và xử lý những prompt không khớp với mẫu cố định.

Có thể triển khai guard model ở nhiều vị trí:

1. **Input guard:** đánh giá prompt trước khi đưa vào LLM chính;
2. **Output guard:** đánh giá phản hồi trước khi gửi cho người dùng;
3. **Tool guard:** kiểm tra lời gọi công cụ và tham số hành động;
4. **Trajectory guard:** đánh giá toàn bộ chuỗi quan sát, kế hoạch và hành động của agent.


Guard models giúp tách nhiệm vụ sinh nội dung khỏi nhiệm vụ đánh giá an toàn. Điều này có lợi vì mô hình chính có thể tối ưu cho khả năng hỗ trợ người dùng, trong khi guard model tập trung vào chính sách an toàn. Tuy nhiên, guard model cũng có thể bị lỗi, bị né tránh hoặc tạo ra over-refusal.

Một vấn đề quan trọng là guard model cần được đánh giá độc lập. Nếu guard được dùng làm evaluator trong benchmark, nhưng chính guard đó cũng được dùng trong hệ thống phòng thủ, kết quả đánh giá có thể bị thiên lệch. Do đó, các benchmark như HarmBench nhấn mạnh nhu cầu chuẩn hóa dữ liệu, attack artifacts và phương pháp chấm điểm khi so sánh các defense [8].

4.9 Defense-in-depth

Không có một cơ chế phòng thủ đơn lẻ nào đủ để bảo vệ hoàn toàn hệ thống LLM trước jailbreak. Input filtering có thể bỏ sót các prompt được diễn đạt tinh vi. Safety alignment có thể không bao phủ mọi biến thể đầu vào. Output moderation có thể phát hiện muộn. Guard models có thể sai hoặc bị attacker thích nghi. Vì vậy, hệ thống thực tế thường cần defense-in-depth, tức là kết hợp nhiều lớp phòng thủ.

Hình 2 minh họa một kiến trúc phòng thủ nhiều lớp cho hệ thống LLM có khả năng gọi công cụ.



Hình 2: Kiến trúc phòng thủ nhiều lớp cho hệ thống LLM có khả năng gọi công cụ.

Trong kiến trúc này, input guard giảm rủi ro trước khi prompt đến mô hình. Aligned LLM chịu trách nhiệm sinh phản hồi theo chính sách đã học. Output guard kiểm tra nội dung trước khi trả về người dùng. Action controller giới hạn quyền của công cụ, kiểm tra tham số hành động và có thể yêu cầu xác nhận cho các thao tác quan trọng. Monitoring ghi nhận log, phát hiện bất thường và hỗ trợ phân tích sau sự cố.

Defense-in-depth đặc biệt quan trọng đối với agentic systems. Khi LLM có thể gọi công cụ, truy cập dữ liệu hoặc thực hiện hành động, rủi ro không chỉ nằm ở văn bản cuối cùng. Một hệ thống an toàn cần kiểm soát cả prompt, context, kế hoạch, lời gọi công cụ, output và trạng thái môi trường.

4.10 Hạn chế của các phương pháp phòng thủ

Mặc dù các phương pháp phòng thủ có thể giảm rủi ro jailbreak, chúng vẫn có những hạn chế chung.

Thứ nhất, không gian đầu vào ngôn ngữ tự nhiên rất lớn. Một defense được đánh giá tốt trên một tập attack cố định có thể không bền vững trước các biến thể mới hoặc adaptive attacks. Do đó, kết quả trên benchmark cần được hiểu như bằng chứng thực nghiệm, không phải bảo đảm tuyệt đối.

Thứ hai, safety và utility thường có sự đánh đổi. Một defense quá nghiêm ngặt có thể làm giảm unsafe compliance nhưng đồng thời tăng over-refusal. Điều này làm hệ thống kém hữu ích, đặc biệt trong các ngữ cảnh mà người dùng có nhu cầu hợp lệ như học tập, nghiên cứu hoặc phân tích rủi ro.

Thứ ba, nhiều defense làm tăng chi phí triển khai. Inference-time defenses có thể cần nhiều lần gọi mô hình; guard models cần tài nguyên riêng; monitoring và human confirmation làm tăng độ phức tạp vận hành. Vì vậy, lựa chọn defense cần cân bằng giữa mức rủi ro, chi phí và yêu cầu ứng dụng.

Thứ tư, defense có thể bị attacker thích nghi. Nếu attacker biết hệ thống dùng input guard, output guard hoặc smoothing, họ có thể điều chỉnh prompt để tối ưu qua các lớp đó. Vì vậy, một defense đáng tin cậy cần được đánh giá trong cả thiết lập static và adaptive.

4.11 Tổng kết chương

Chương này đã trình bày các nhóm phòng thủ chính trước jailbreak, bao gồm input filtering, prompt preprocessing, adversarial training, inference-time defenses, output moderation, representation-level defenses, guard models và defense-in-depth. Mỗi nhóm defense có ưu điểm và hạn chế riêng, phụ thuộc vào vị trí triển khai, quyền truy cập mô hình, chi phí suy luận và loại attack cần chống lại.

Một kết luận quan trọng là không nên phụ thuộc vào một lớp phòng thủ duy nhất. Jailbreak là một bài toán động, trong đó attacker có thể thay đổi cách diễn đạt, tự động hóa tìm kiếm prompt hoặc thích nghi với defense. Do đó, các hệ thống thực tế cần kết hợp nhiều lớp bảo vệ và đánh giá chúng trên cả safety, utility, over-refusal, chi phí và khả năng chống adaptive attacks.

Chương tiếp theo trình bày các phương pháp evaluation và benchmark dùng để đo lường attack success, refusal, harmfulness, utility và độ bền vững của các defense.

5 Evaluation and Benchmarks

Các chương trước đã trình bày các nhóm jailbreak attacks và jailbreak defenses. Tuy nhiên, việc so sánh attack hoặc defense không thể chỉ dựa trên mô tả định tính. Cần có một quy trình đánh giá rõ ràng để trả lời các câu hỏi: attack có thành công hay không, defense có làm giảm rủi ro không, mô hình có từ chối quá mức không, chi phí suy luận tăng bao nhiêu, và kết quả có thể tái lập trên benchmark khác hay không.

Chương này trình bày các mục tiêu đánh giá, metric thường dùng, phương pháp chấm điểm và các benchmark tiêu biểu trong nghiên cứu jailbreaking LLMs. Nội dung tập trung vào Attack Success Rate, refusal, harmfulness, utility, over-refusal, human evaluation, classifier-based evaluation, LLM-as-a-judge, AdvBench, HarmBench và JailbreakBench.

5.1 Mục tiêu đánh giá

Đánh giá jailbreak không chỉ nhằm đo xem một attack có vượt qua mô hình hay không. Một quy trình đánh giá đầy đủ cần xem xét đồng thời nhiều khía cạnh:

1. **Safety:** hệ thống có tránh tạo phản hồi không an toàn trước harmful hoặc adversarial prompts hay không;
2. **Utility:** hệ thống có tiếp tục hỗ trợ tốt các yêu cầu hợp lệ hay không;
3. **Robustness:** hệ thống có duy trì hành vi an toàn trước nhiều dạng attack, nhiều mô hình và nhiều biến thể prompt hay không;
4. **Cost:** attack hoặc defense cần bao nhiêu truy vấn, thời gian, token và tài nguyên tính toán;
5. **Reproducibility:** kết quả có thể được tái lập với cùng dữ liệu, prompt, system prompt, evaluator và scoring rule hay không.

Một lỗi phổ biến trong đánh giá jailbreak là chỉ báo cáo tỷ lệ attack thành công mà không đo utility. Một defense luôn từ chối mọi yêu cầu có thể đạt safety cao trên tập harmful prompts, nhưng lại không hữu ích trong triển khai thực tế. Ngược lại, một mô hình rất hữu ích nhưng chấp nhận nhiều yêu cầu không an toàn cũng không đạt yêu cầu về safety.

Vì vậy, evaluation cần được thiết kế như một bài toán cân bằng giữa safety và utility, thay vì chỉ tối ưu một metric đơn lẻ.

5.2 Attack Success Rate

Attack Success Rate (ASR) là metric phổ biến nhất trong nghiên cứu jailbreak. ASR đo tỷ lệ test cases mà attack khiến hệ thống tạo ra phản hồi bị xem là không an toàn hoặc không phù hợp với chính sách.

Giả sử có tập kiểm thử gồm N hành vi hoặc yêu cầu cần đánh giá. Với mỗi trường hợp i , đặt biến nhị phân $z_i = 1$ nếu attack thành công và $z_i = 0$ nếu không thành công. Khi đó ASR được tính bởi

$$\text{ASR} = \frac{1}{N} \sum_{i=1}^N z_i. \quad (20)$$

ASR càng cao thì attack càng hiệu quả hoặc defense càng yếu. Tuy nhiên, ASR phụ thuộc mạnh vào cách định nghĩa “thành công”. Một phản hồi có thể chứa dấu hiệu tuân thủ một phần, từ chối một phần, hoặc cung cấp thông tin ở mức khái quát. Nếu evaluator không nhất quán, ASR giữa các công trình sẽ khó so sánh.

Ngoài ra, ASR cần được báo cáo kèm theo điều kiện đánh giá:

- tập hành vi được dùng là gì;
- target model và system prompt nào được sử dụng;
- attack có bao nhiêu ngân sách truy vấn;
- evaluator là con người, classifier hay LLM-as-a-judge;
- scoring rule có tính partial compliance hay không;
- defense có được attacker biết trước hay không.

Nếu thiếu các thông tin này, cùng một giá trị ASR có thể mang ý nghĩa rất khác nhau.

5.3 Refusal và harmfulness

Trong đánh giá jailbreak, hai khái niệm quan trọng là *refusal* và *harmfulness*. Refusal mô tả việc mô hình từ chối hoặc chuyển hướng yêu cầu. Harmfulness mô tả mức độ phản hồi chứa nội dung không phù hợp với chính sách an toàn.

Hai khái niệm này có liên hệ nhưng không hoàn toàn đồng nhất. Một phản hồi có thể không chứa nội dung gây hại nhưng cũng không từ chối rõ ràng. Ngược lại, một phản hồi có thể bắt đầu bằng câu từ chối nhưng sau đó vẫn cung cấp nội dung không phù hợp. Vì vậy, chỉ phát hiện sự xuất hiện của các cụm từ từ chối là chưa đủ để đánh giá an toàn.

Có thể mô tả kết quả đầu ra theo bốn trường hợp trong Bảng 6.

Bảng 6: Quan hệ giữa refusal và harmfulness trong đánh giá phản hồi.

Refusal	Harmfulness	Diễn giải
Có	Thấp	Phản hồi an toàn, mô hình từ chối hoặc chuyển hướng phù hợp.
Có	Cao	Phản hồi không nhất quán: có dấu hiệu từ chối nhưng vẫn chứa nội dung không phù hợp.
Không	Thấp	Phản hồi có thể hợp lệ nếu yêu cầu ban đầu là benign; với harmful prompt, trường hợp này cần được kiểm tra kỹ.
Không	Cao	Unsafe compliance; đây thường là trường hợp attack thành công.

Do đó, evaluator tốt cần đánh giá cả cấu trúc từ chối lẫn nội dung thực sự của phản hồi. Đối với các mô hình hiện đại, việc chấm điểm cần xét toàn bộ phản hồi thay vì dựa trên vài từ khóa đầu câu.

5.4 Utility và over-refusal

Nếu ASR đo khả năng attack khiến mô hình tạo phản hồi không an toàn, thì utility đo khả năng mô hình vẫn hỗ trợ yêu cầu hợp lệ. Một defense làm ASR giảm nhưng khiến mô hình từ chối nhiều yêu cầu benign có thể không phù hợp để triển khai.

Over-refusal xảy ra khi mô hình từ chối một yêu cầu hợp lệ. Gọi M là số benign prompts trong tập đánh giá và $r_j = 1$ nếu mô hình từ chối sai yêu cầu benign thứ j , over-refusal rate có thể được tính bởi

$$\text{ORR} = \frac{1}{M} \sum_{j=1}^M r_j. \quad (21)$$

Một defense lý tưởng cần giảm ASR trên harmful prompts nhưng không làm ORR tăng quá cao trên benign prompts. Vì vậy, báo cáo kết quả nên tách rõ hai tập đánh giá:

1. **Harmful/adversarial set:** dùng để đo ASR, harmfulness và robust refusal;
2. **Benign set:** dùng để đo utility, helpfulness và over-refusal.

Trong thực tế, utility có thể được đo bằng nhiều cách: tỷ lệ trả lời đúng, điểm helpfulness do con người đánh giá, LLM-as-a-judge, hoặc metric theo nhiệm vụ cụ thể. Với các hệ thống agent, utility còn cần xét việc agent có hoàn thành đúng nhiệm vụ, dùng công cụ đúng cách và không gây tác dụng phụ không mong muốn hay không.

5.5 Human evaluation

Human evaluation là phương pháp chấm điểm bằng người đánh giá. Đây thường được xem là chuẩn tham chiếu quan trọng vì con người có thể hiểu ngữ cảnh, ẩn ý, mức độ tuân thủ một phần và sự khác biệt giữa nội dung phân tích an toàn với nội dung không phù hợp.

Ưu điểm của human evaluation là độ linh hoạt cao. Người đánh giá có thể xem xét toàn bộ prompt, phản hồi, chính sách và bối cảnh để đưa ra nhận. Điều này đặc biệt hữu ích trong các trường hợp phản hồi mơ hồ, có nhiều phần hoặc chứa cả từ chối lẫn nội dung rủi ro.

Tuy nhiên, human evaluation có các hạn chế sau:

- chi phí cao và khó mở rộng trên tập dữ liệu lớn;
- kết quả có thể phụ thuộc vào hướng dẫn chấm điểm;

- các annotator khác nhau có thể đánh giá không nhất quán;
- cần kiểm soát chất lượng và đo inter-annotator agreement;
- khó tái lập nếu guideline hoặc nhóm annotator không được mô tả rõ.

Vì vậy, human evaluation thường phù hợp với tập đánh giá nhỏ, tập kiểm tra chất lượng hoặc dùng làm ground truth để hiệu chỉnh evaluator tự động.

5.6 Classifier-based evaluation

Classifier-based evaluation sử dụng một mô hình phân loại để xác định phản hồi có an toàn hay không, có từ chối hay không, hoặc có thuộc một nhóm chính sách cụ thể hay không. Classifier có thể là mô hình học máy truyền thống, transformer encoder hoặc một guard model được huấn luyện riêng.

Ưu điểm của classifier-based evaluation là tốc độ cao, chi phí thấp hơn human evaluation và dễ áp dụng trên tập dữ liệu lớn. Nó cũng giúp chuẩn hóa quy trình chấm điểm nếu classifier và ngưỡng quyết định được công bố rõ ràng.

Tuy nhiên, classifier cũng có thể sai. Một classifier dựa quá nhiều vào từ khóa có thể đánh giá sai các phản hồi có ngữ cảnh giáo dục hoặc nghiên cứu. Ngược lại, classifier có thể bỏ sót các phản hồi không an toàn được diễn đạt gián tiếp. Ngoài ra, nếu attacker biết hoặc suy đoán classifier, họ có thể tối ưu prompt để né evaluator.

Một vấn đề khác là evaluator bias. Nếu cùng một classifier được dùng để huấn luyện defense và đánh giá defense, kết quả có thể bị thiên lệch theo classifier đó. Vì vậy, classifier-based evaluation nên được kiểm tra chéo với human evaluation hoặc LLM-as-a-judge trong các trường hợp quan trọng.

5.7 LLM-as-a-judge

LLM-as-a-judge sử dụng một mô hình ngôn ngữ khác để đánh giá phản hồi của target model. Judge model nhận prompt, phản hồi, rubric và chính sách đánh giá, sau đó đưa ra nhãn hoặc điểm số. Phương pháp này ngày càng phổ biến vì có thể mở rộng tốt hơn human evaluation nhưng linh hoạt hơn classifier truyền thống.

Một thiết lập LLM-as-a-judge có thể được mô tả bởi

$$\hat{z} = J_{\phi}(x, y, R), \quad (22)$$

trong đó x là prompt, y là phản hồi của target model, R là rubric đánh giá và J_{ϕ} là judge model. Đầu ra $\hat{z}$ có thể là nhãn thành công/thất bại, mức độ harmfulness hoặc điểm helpfulness.

Ưu điểm của LLM-as-a-judge là khả năng xử lý ngữ cảnh phức tạp và diễn giải kết quả. Judge model có thể đánh giá partial compliance, phát hiện mâu thuẫn giữa phần từ

chối và phần nội dung, hoặc phân biệt giữa thảo luận an toàn với hướng dẫn không phù hợp.

Tuy nhiên, LLM-as-a-judge cũng có hạn chế:

- judge có thể không nhất quán giữa các lần chạy;
- kết quả phụ thuộc vào rubric và prompt chấm điểm;
- judge có thể bị ảnh hưởng bởi văn phong của phản hồi;
- judge model cũng có giới hạn safety và bias riêng;
- nếu dùng API đóng, kết quả có thể thay đổi theo thời gian.

Do đó, khi sử dụng LLM-as-a-judge, báo cáo nên mô tả rõ judge model, rubric, temperature, format đầu ra và cách xử lý trường hợp không chắc chắn. Với benchmark quan trọng, nên kết hợp LLM judge với kiểm tra thủ công trên mẫu con để ước lượng độ tin cậy.

5.8 AdvBench

AdvBench là một benchmark thường được sử dụng trong nghiên cứu jailbreak, đặc biệt trong các công trình về adversarial suffix và attack có khả năng chuyển giao. Benchmark này gồm các harmful behaviors được viết dưới dạng instruction, dùng để kiểm tra liệu attack có khiến mô hình tạo phản hồi cố gắng tuân thủ yêu cầu không phù hợp hay không [2].

Trong thiết lập điển hình, attacker tạo một chuỗi bổ sung hoặc một biến thể prompt cho từng behavior. Sau đó target model được truy vấn, và evaluator xác định phản hồi có phải unsafe compliance hay không. AdvBench hữu ích vì cung cấp một tập hành vi chuẩn để so sánh các attack ở mức text-only LLM.

Tuy nhiên, AdvBench cũng có hạn chế. Thứ nhất, benchmark chủ yếu tập trung vào harmful instructions dạng văn bản, nên chưa bao phủ đầy đủ multi-turn jailbreak, prompt injection trong agentic systems hoặc tool-use attacks. Thứ hai, cách chấm điểm trong các công trình khác nhau có thể không hoàn toàn thống nhất. Thứ ba, nếu chỉ đánh giá trên AdvBench, kết quả có thể không phản ánh đầy đủ utility và over-refusal trên benign prompts.

Vì vậy, AdvBench phù hợp để đánh giá ban đầu về robustness của LLM trước một tập harmful behaviors chuẩn, nhưng nên được kết hợp với benchmark khác và tập benign để có đánh giá cân bằng hơn.

5.9 HarmBench

HarmBench được đề xuất như một framework chuẩn hóa cho automated red teaming và robust refusal [8]. Mục tiêu của HarmBench là giảm tình trạng các công trình sử dụng tập hành vi, attack, target model và evaluator khác nhau khiến kết quả khó so sánh trực tiếp.

HarmBench nhấn mạnh một số yêu cầu quan trọng trong đánh giá jailbreak:

- tập hành vi cần rõ ràng và có cấu trúc;
- attack methods cần được mô tả và triển khai nhất quán;
- target models và defenses cần được đánh giá trong cùng quy trình;
- evaluator cần được chuẩn hóa để giảm sai khác giữa các công trình;
- kết quả cần hỗ trợ so sánh giữa automated red teaming methods.

Điểm mạnh của HarmBench là nó xem evaluation như một framework toàn diện, không chỉ là một tập prompt. Điều này phù hợp với nhu cầu so sánh attack và defense trong một pipeline thống nhất. Ngoài ra, HarmBench còn nhấn mạnh robust refusal, tức là khả năng mô hình duy trì từ chối an toàn trước nhiều dạng attack.

Tuy nhiên, giống các benchmark khác, HarmBench vẫn không thể bao phủ toàn bộ không gian rủi ro. Kết quả trên HarmBench cần được hiểu là bằng chứng thực nghiệm trong một thiết lập chuẩn hóa, không phải bảo đảm tuyệt đối về an toàn trong mọi ngữ cảnh triển khai.

5.10 JailbreakBench

JailbreakBench là một benchmark mở nhằm chuẩn hóa đánh giá jailbreak trên LLMs [9]. Benchmark này được xây dựng để giải quyết một số vấn đề trong các đánh giá trước đó, bao gồm thiếu chuẩn thực hành chung, cách tính chi phí và success rate không thống nhất, cũng như khó tái lập do thiếu adversarial prompts hoặc phụ thuộc vào API thay đổi theo thời gian.

JailbreakBench cung cấp một số thành phần quan trọng:

1. repository các jailbreak artifacts;
2. tập behaviors dùng cho đánh giá;
3. framework đánh giá với threat model, system prompt, chat template và scoring functions được định nghĩa rõ;
4. leaderboard để theo dõi kết quả của attacks và defenses trên các mô hình khác nhau.

So với việc chỉ dùng một tập prompt tĩnh, JailbreakBench nhấn mạnh tính mở, khả năng tái lập và so sánh công bằng. Điều này đặc biệt quan trọng vì jailbreak research có tính động: attack mới xuất hiện, defense mới được đề xuất, và mô hình triển khai cũng thay đổi theo thời gian.

Tuy nhiên, JailbreakBench cũng cần được sử dụng cẩn thận. Một leaderboard có thể thúc đẩy tối ưu hóa quá mức trên benchmark cụ thể. Ngoài ra, các kết quả trên benchmark text-only không nhất thiết phản ánh đầy đủ rủi ro trong agentic systems, nơi lời gọi công cụ, memory và trạng thái môi trường cũng cần được đánh giá.

5.11 So sánh các benchmark

Bảng 7 tóm tắt vai trò của ba benchmark thường gặp trong nghiên cứu jailbreak.

Bảng 7: So sánh khái quát AdvBench, HarmBench và JailbreakBench.

Benchmark	Trọng tâm	Điểm mạnh	Hạn chế chính
AdvBench	Harmful behaviors cho text-based jailbreak	Đơn giản, phổ biến, hữu ích để đánh giá attack như adversarial suffix	Chưa bao phủ tốt utility, multi-turn, agentic systems và tool-use risks.
HarmBench	Automated teaming và robust refusal	Framework chuẩn hóa để so sánh attacks, models và defenses	Vẫn là benchmark hữu hạn, không thể đại diện toàn bộ không gian rủi ro.
JailbreakBench	Benchmark mở cho jailbreak robustness	Nhấn mạnh reproducibility, threat model, scoring functions và leaderboard	Có nguy cơ bị tối ưu hóa quá mức theo benchmark; cần mở rộng cho agentic settings.

Ba benchmark này bổ sung cho nhau. AdvBench phù hợp để đánh giá cơ bản trên harmful behaviors dạng văn bản. HarmBench phù hợp với so sánh automated red teaming và robust refusal. JailbreakBench phù hợp với mục tiêu tái lập, chuẩn hóa và theo dõi tiến bộ của attacks/defenses.

5.12 Đánh giá trong agentic systems

Đối với chatbot, đơn vị đánh giá thường là một phản hồi hoặc một cuộc hội thoại. Đối với agentic systems, đánh giá cần mở rộng sang toàn bộ trajectory, bao gồm observation, plan, tool call, tool output và final response.

Một trajectory có thể được biểu diễn bởi

$$\tau = (o_0, a_0, o_1, a_1, \dots, o_T), \quad (23)$$

trong đó o_t là observation và a_t là hành động tại thời điểm t . Evaluator cần kiểm tra không chỉ phản hồi cuối cùng mà còn cả các bước trung gian.

Một agent có thể tạo final response an toàn nhưng đã thực hiện một tool call không phù hợp trước đó. Ngược lại, agent có thể lập kế hoạch rủi ro nhưng bị action controller chặn lại. Vì vậy, evaluation cho agent cần có các metric bổ sung:

- tỷ lệ tool calls không phù hợp;
- tỷ lệ hành động bị guard chặn;
- mức độ agent tuân thủ quyền hạn công cụ;
- mức độ hoàn thành nhiệm vụ hợp lệ;
- tác động của prompt injection gián tiếp từ external content;
- chi phí và độ trễ của guard trên từng bước trajectory.

Nội dung này sẽ được phân tích sâu hơn trong Chương 6, nhưng cần được đặt trong chương evaluation để nhấn mạnh rằng benchmark cho LLM sinh văn bản chưa đủ cho các hệ thống có khả năng hành động.

5.13 Hạn chế chung của evaluation hiện tại

Mặc dù các benchmark hiện tại đã cải thiện đáng kể khả năng so sánh giữa các attack và defense, evaluation jailbreak vẫn còn nhiều hạn chế.

Thứ nhất, không gian đầu vào ngôn ngữ tự nhiên rất lớn và thay đổi liên tục. Một benchmark hữu hạn không thể bao phủ tất cả biến thể prompt, ngôn ngữ, ngữ cảnh và chiến lược attacker.

Thứ hai, evaluator có thể không ổn định. Human evaluation tốn kém và phụ thuộc annotator; classifier-based evaluation có thể sai trong trường hợp mơ hồ; LLM-as-a-judge phụ thuộc vào rubric, model version và prompt chấm điểm.

Thứ ba, nhiều kết quả khó so sánh do khác biệt về system prompt, chat template, decoding parameters, ngân sách truy vấn và cách tính success. Ngay cả khi cùng dùng một benchmark, thay đổi nhỏ trong thiết lập cũng có thể làm kết quả khác đi.

Thứ tư, benchmark có thể tạo ra benchmark overfitting. Nếu attack hoặc defense được tối ưu nhiều lần trên cùng một tập đánh giá, kết quả có thể không chuyển giao tốt sang tình huống thực tế.

Thứ năm, evaluation text-only chưa đủ cho agentic systems. Khi LLM có thể gọi công cụ hoặc điều khiển môi trường, rủi ro có thể nằm ở hành động trung gian chứ không chỉ ở văn bản cuối cùng.

5.14 Tổng kết chương

Chương này đã trình bày các thành phần chính trong đánh giá jailbreak: Attack Success Rate, refusal, harmfulness, utility, over-refusal, human evaluation, classifier-based evaluation, LLM-as-a-judge và các benchmark tiêu biểu như AdvBench, HarmBench và JailbreakBench.

Một kết luận quan trọng là không có metric đơn lẻ nào đủ để đánh giá đầy đủ jailbreak robustness. ASR cho biết attack có thành công hay không, nhưng không phản ánh utility. Refusal rate cho biết mô hình có từ chối hay không, nhưng không bảo đảm phản hồi không chứa nội dung không phù hợp. Classifier-based evaluation có khả năng mở rộng, nhưng cần kiểm tra độ tin cậy. LLM-as-a-judge linh hoạt, nhưng phụ thuộc vào rubric và model version.

Do đó, đánh giá jailbreak nên được thiết kế như một pipeline gồm nhiều metric và nhiều evaluator. Kết quả cần được báo cáo kèm threat model, tập dữ liệu, target model, system prompt, ngân sách truy vấn, scoring rule và chi phí. Với agentic systems, evaluation cần mở rộng từ phản hồi cuối sang toàn bộ trajectory. Đây là cơ sở để chương tiếp theo phân tích rủi ro và phòng thủ trong các hệ thống LLM có bộ nhớ, công cụ và khả năng hành động.

6 Agentic Systems

Các chương trước tập trung vào jailbreak attacks, defenses và evaluation đối với LLM sinh văn bản. Tuy nhiên, khi LLM được tích hợp vào hệ thống có bộ nhớ, khả năng lập kế hoạch, truy xuất dữ liệu và gọi công cụ, bài toán an toàn không còn chỉ nằm ở phản hồi cuối cùng. Một agent có thể đọc dữ liệu từ nguồn bên ngoài, ra quyết định nhiều bước, gọi API, ghi bộ nhớ hoặc tương tác với môi trường. Vì vậy, rủi ro jailbreak và prompt injection cần được phân tích ở cấp toàn bộ trajectory của hệ thống.

Chương này trình bày tổng quan về LLM agents, bề mặt tấn công của agent, prompt injection trực tiếp và gián tiếp, tool-use attacks, memory poisoning, jailbreaking đối với robot được điều khiển bởi LLM, các phương pháp phòng thủ đặc thù cho agent và benchmark cho agent security.

6.1 Tổng quan LLM agents

Một chatbot thông thường nhận prompt từ người dùng và sinh phản hồi văn bản. Ngược lại, một LLM agent sử dụng mô hình ngôn ngữ như bộ điều khiển cho một vòng lặp hành động. Agent không chỉ trả lời câu hỏi mà còn có thể lập kế hoạch, gọi công cụ, quan sát kết quả và điều chỉnh bước tiếp theo.

Một agent đơn giản có thể được mô tả bởi vòng lặp sau:

$$o_t \rightarrow p_t \rightarrow a_t \rightarrow o_{t+1}, \quad (24)$$

trong đó o_t là observation tại thời điểm t , p_t là kế hoạch hoặc suy luận trung gian, a_t là hành động được chọn và o_{t+1} là quan sát mới sau khi hành động được thực thi.

Trong thực tế, một agent thường gồm các thành phần chính:

- **LLM controller:** mô hình ngôn ngữ chịu trách nhiệm diễn giải nhiệm vụ, lập kế hoạch và chọn hành động;
- **Memory:** bộ nhớ ngắn hạn hoặc dài hạn dùng để lưu thông tin từ các lượt tương tác trước;
- **Planner:** thành phần tạo kế hoạch nhiều bước hoặc phân rã nhiệm vụ;
- **Tools:** các công cụ bên ngoài như search, database, email, file system, code interpreter hoặc API ứng dụng;
- **Environment:** môi trường mà agent quan sát và tác động, chẳng hạn website, tài liệu, hệ thống phần mềm hoặc robot;
- **Guard/monitor:** các lớp kiểm soát an toàn, logging và xác nhận hành động.

Chính việc bổ sung memory, tools và environment làm tăng đáng kể bề mặt tấn công. Trong chatbot, attacker chủ yếu tác động qua prompt trực tiếp. Trong agentic system, attacker còn có thể tác động qua dữ liệu được retrieval, tool output, memory entry, trạng thái website hoặc môi trường vật lý.

6.2 Bề mặt tấn công của agent

Bề mặt tấn công của agent rộng hơn chatbot vì agent xử lý nhiều nguồn dữ liệu và thực hiện nhiều loại hành động hơn. Thay vì chỉ đánh giá một phản hồi văn bản, cần xét toàn bộ pipeline từ prompt đầu vào đến các bước lập kế hoạch, truy xuất dữ liệu, gọi công cụ và phản hồi cuối.

Bảng 8 tóm tắt các điểm tấn công chính trong một agentic system.

Bảng 8: Bề mặt tấn công chính trong hệ thống LLM agent.

Thành phần	Kênh tấn công	Rủi ro chính
User prompt	Chỉ dẫn trực tiếp từ người dùng	Jailbreak, direct prompt injection hoặc yêu cầu vượt chính sách.
External content	Website, email, tài liệu, kết quả retrieval	Indirect prompt injection, dữ liệu không đáng tin cậy bị hiểu nhầm là instruction.
Memory	Thông tin được lưu qua nhiều phiên	Memory poisoning, ghi nhớ sai lệch hoặc lưu chỉ dẫn không đáng tin cậy.
Planner	Kế hoạch trung gian của agent	Phân rã nhiệm vụ theo hướng sai, bỏ qua ràng buộc hoặc chọn hành động không phù hợp.
Tools	API, database, file system, browser, code runner	Tool misuse, rò rỉ dữ liệu, thao tác ngoài quyền hạn hoặc gọi công cụ sai ngữ cảnh.
Tool output	Dữ liệu trả về từ công cụ	Nội dung độc hại hoặc chỉ dẫn gián tiếp được đưa ngược vào context.
Environment	Website, ứng dụng, robot hoặc hệ thống vật lý	Hành động có tác động bên ngoài, khó đảo ngược hoặc ảnh hưởng đến người dùng khác.

Điểm cốt lõi là agent thường đặt nhiều loại dữ liệu vào cùng một context window. Nếu hệ thống không phân tách rõ instruction, user request và external content, mô hình có thể bị thuyết phục làm theo những chỉ dẫn không đáng tin cậy. Đây là lý do agent security cần được thiết kế ở cấp kiến trúc, không chỉ dựa trên hành vi từ chối của LLM.

6.3 Prompt injection trực tiếp và gián tiếp

Prompt injection là dạng tấn công trong đó attacker đưa chỉ dẫn vào context nhằm làm thay đổi luồng điều khiển của ứng dụng LLM. Có thể phân biệt hai dạng chính: direct prompt injection và indirect prompt injection.

Direct prompt injection xuất hiện khi người dùng trực tiếp đưa chỉ dẫn đối nghịch vào prompt. Trong trường hợp này, attacker và user thường là cùng một thực thể. Mục tiêu là khiến mô hình bỏ qua hoặc làm sai lệch các chỉ dẫn cấp cao hơn, chẳng hạn system instruction hoặc application instruction.

Indirect prompt injection xuất hiện khi chỉ dẫn đối nghịch không nằm trong prompt trực tiếp của người dùng, mà nằm trong dữ liệu bên ngoài được agent đọc hoặc

truy xuất. Ví dụ, nội dung từ một trang web, tài liệu, email hoặc tool output có thể chứa câu lệnh làm agent thay đổi kế hoạch. Người dùng có thể không biết rằng dữ liệu bên ngoài chứa chỉ dẫn đó.

Greshake et al. chỉ ra rằng các ứng dụng tích hợp LLM làm mờ ranh giới giữa dữ liệu và chỉ dẫn: nội dung được retrieval hoặc xử lý như dữ liệu vẫn có thể ảnh hưởng đến hành vi điều khiển của ứng dụng [10]. Đối với agent, vấn đề này nghiêm trọng hơn chatbot vì agent có thể hành động dựa trên dữ liệu đã bị thao túng.

Có thể biểu diễn indirect prompt injection bằng luồng sau:

$$u \rightarrow R(q) \rightarrow c_{\text{ext}} \rightarrow F_{\theta}(u, c_{\text{ext}}, s) \rightarrow a, \quad (25)$$

trong đó u là yêu cầu hợp lệ của người dùng, $R(q)$ là bước retrieval hoặc tool call, c_{ext} là nội dung bên ngoài không đáng tin cậy, s là system instruction và a là hành động của agent. Nếu c_{ext} chứa chỉ dẫn đối nghịch nhưng được mô hình xử lý như instruction, agent có thể thực hiện hành động ngoài ý định ban đầu.

6.4 Tool-use attacks

Tool-use attacks nhắm vào khả năng agent gọi công cụ. Trong chatbot, phản hồi không an toàn thường là văn bản. Trong agentic system, rủi ro có thể nằm ở việc agent chọn sai công cụ, truyền sai tham số, truy xuất dữ liệu không nên truy xuất hoặc thực hiện thao tác không phù hợp.

Một lời gọi công cụ có thể được mô tả bởi

$$a_t = (\text{tool}_t, \text{args}_t), \quad (26)$$

trong đó tool_t là công cụ được chọn và args_t là tập tham số truyền vào công cụ. Tool-use attack có thể tác động vào cả hai thành phần này: làm agent chọn công cụ không phù hợp hoặc làm sai lệch tham số hành động.

Các rủi ro thường gặp ở mức khái niệm gồm:

- agent gọi công cụ khi chưa có đủ quyền hoặc chưa cần thiết;
- agent truyền dữ liệu nhạy cảm vào công cụ không đáng tin cậy;
- agent dùng kết quả từ công cụ như instruction thay vì data;
- agent bỏ qua bước xác nhận người dùng trước hành động quan trọng;
- agent thực hiện chuỗi hành động đúng từng bước cục bộ nhưng sai mục tiêu tổng thể.

Do đó, phòng thủ cho tool-use không thể chỉ dựa vào output moderation. Hệ thống cần kiểm tra trước khi gọi công cụ, giới hạn quyền theo nguyên tắc least privilege, phân

loại công cụ theo mức rủi ro và yêu cầu xác nhận với các hành động có tác động bên ngoài.

6.5 Memory poisoning

Memory giúp agent duy trì thông tin qua nhiều lượt tương tác hoặc nhiều phiên làm việc. Tuy nhiên, memory cũng tạo ra bề mặt tấn công mới. Nếu attacker có thể làm agent ghi một thông tin sai lệch hoặc một chỉ dẫn không đáng tin cậy vào bộ nhớ, thông tin đó có thể ảnh hưởng đến các quyết định trong tương lai.

Có thể mô tả bộ nhớ dài hạn của agent tại thời điểm t là M_t . Sau một tương tác mới, agent cập nhật bộ nhớ bằng hàm ghi nhớ:

$$M_{t+1} = \text{Write}(M_t, e_t), \quad (27)$$

trong đó e_t là thông tin được trích xuất từ tương tác hiện tại. Memory poisoning xảy ra khi e_t chứa thông tin không đáng tin cậy nhưng vẫn được ghi vào M_{t+1} và sau đó được retrieval trong một nhiệm vụ khác.

Rủi ro của memory poisoning nằm ở tính bền vững. Một prompt injection thông thường có thể chỉ ảnh hưởng đến một phiên làm việc. Ngược lại, memory poisoning có thể tạo ảnh hưởng dài hạn nếu agent tiếp tục truy xuất và tin vào memory đã bị nhiễm. Vấn đề này đặc biệt quan trọng với các assistant cá nhân hóa, web agents hoặc enterprise agents có bộ nhớ lâu dài.

Các biện pháp giảm thiểu ở mức hệ thống gồm:

- phân biệt rõ memory về sự kiện, sở thích và instruction;
- không cho phép external content tự động trở thành chỉ dẫn dài hạn;
- gắn metadata về nguồn, thời điểm và mức độ tin cậy cho memory;
- yêu cầu xác nhận trước khi ghi các memory có ảnh hưởng lớn;
- định kỳ kiểm tra, làm sạch hoặc hết hạn các memory rủi ro;
- dùng trust-aware retrieval để ưu tiên memory đáng tin cậy.

Nói cách khác, memory không nên được xem là vùng lưu trữ mặc định đáng tin cậy. Nó cần có cơ chế kiểm soát quyền ghi, quyền đọc và độ tin cậy giống như các thành phần dữ liệu khác trong hệ thống.

6.6 Jailbreaking LLM-controlled robots

Khi LLM được dùng để điều khiển robot hoặc hệ thống vật lý, rủi ro jailbreak vượt ra ngoài văn bản. Một phản hồi không an toàn trong chatbot có thể gây hại ở mức thông

tin. Trong robot, hành vi không an toàn có thể trở thành hành động trong môi trường thực. Vì vậy, đánh giá an toàn cần xem xét cả lời gọi hành động, trạng thái robot, ràng buộc vật lý và cơ chế dừng khẩn cấp.

RoboPAIR là một công trình tiêu biểu mở rộng jailbreak từ chatbot sang LLM-controlled robots [11]. Thay vì chỉ đánh giá xem mô hình có sinh văn bản không an toàn hay không, hướng nghiên cứu này xem xét liệu một hệ thống robot do LLM điều khiển có thể bị dẫn đến hành động trái với chính sách an toàn hay không.

Trong bối cảnh robot, một action có thể được biểu diễn bởi

$$a_t = \text{Act}(p_t, o_t, r_t), \quad (28)$$

trong đó p_t là kế hoạch, o_t là quan sát môi trường và r_t là tập ràng buộc an toàn. Một hệ thống an toàn cần bảo đảm rằng action cuối cùng không chỉ hợp lệ về mặt ngôn ngữ mà còn hợp lệ về mặt vật lý, quyền hạn và bối cảnh.

Do đó, robot hoặc embodied agents cần nhiều lớp bảo vệ hơn chatbot:

- giới hạn không gian hành động mà LLM được phép đề xuất;
- dùng controller xác minh hành động trước khi thực thi;
- yêu cầu xác nhận con người với hành động rủi ro cao;
- áp dụng sandbox hoặc simulation trước khi hành động thật;
- dùng safety monitor độc lập với LLM;
- có cơ chế dừng khẩn cấp và rollback khi khả thi.

Điểm quan trọng là LLM không nên là lớp quyết định an toàn cuối cùng cho hệ thống vật lý. Các ràng buộc an toàn cần được thực thi ở cấp controller và môi trường, nơi có thể kiểm soát trực tiếp hành động.

6.7 Agent-specific defenses

Defense cho chatbot thường tập trung vào input guard, model alignment và output moderation. Với agentic systems, các defense này vẫn cần thiết nhưng chưa đủ. Agent cần các cơ chế bảo vệ bổ sung ở cấp context, memory, tool, trajectory và permission.

Bảng 9 tóm tắt các nhóm phòng thủ đặc thù cho agent.

Bảng 9: Các nhóm phòng thủ đặc thù cho agentic systems.

Nhóm defense	Cơ chế chính	Mục tiêu
Context isolation	Tách system instruction, user instruction và external content	Giảm khả năng dữ liệu ngoài bị hiểu nhầm là instruction.
Tool permission	Gán quyền truy cập công cụ theo nhiệm vụ, vai trò và mức rủi ro	Ngăn agent gọi công cụ ngoài phạm vi cần thiết.
Action validation	Kiểm tra công cụ và tham số trước khi thực thi	Chặn hành động có tác động không mong muốn.
Human confirmation	Yêu cầu xác nhận với hành động nhạy cảm hoặc không thể đảo ngược	Giảm rủi ro khi agent không chắc chắn hoặc hành động có hậu quả lớn.
Memory access control	Kiểm soát quyền ghi, đọc và xóa memory	Giảm memory poisoning và retrieval từ nguồn không đáng tin cậy.
Trajectory monitoring	Giám sát kế hoạch, tool calls và trạng thái trung gian	Phát hiện rủi ro trước khi final response hoặc hành động cuối xảy ra.
Sandboxing	Thực thi hành động trong môi trường giới hạn	Giảm tác động khi agent hoặc tool bị thao túng.
Least privilege	Chỉ cấp quyền tối thiểu cần thiết cho từng nhiệm vụ	Giới hạn thiệt hại nếu một bước của agent bị compromise.

Một nguyên tắc quan trọng là agent không nên tự quyết định toàn bộ quyền hạn của mình. Nếu LLM vừa lập kế hoạch, vừa chọn công cụ, vừa tự phê duyệt hành động và vừa đánh giá an toàn, hệ thống dễ rơi vào single point of failure. Thay vào đó, cần tách vai trò giữa LLM controller, permission system, action validator và monitoring layer.

6.8 Benchmark cho agent security

Benchmark cho chatbot thường đánh giá prompt và response. Benchmark cho agent cần đánh giá task completion, tool-use correctness, security violation, indirect prompt injection và khả năng duy trì utility dưới tấn công. Do đó, benchmark agent security phức tạp hơn benchmark text-only.

AgentDojo là một benchmark tiêu biểu cho prompt injection attacks và defenses trong LLM agents [12]. Benchmark này đánh giá agent trong môi trường có công cụ và dữ liệu không đáng tin cậy, nhấn mạnh cả utility và security. Điểm quan trọng là AgentDojo

không chỉ là một tập prompt tĩnh mà là môi trường động để thiết kế task, attack và defense.

Agent Security Bench (ASB) mở rộng hướng đánh giá agent security bằng cách formalize nhiều loại attack và defense trong các kịch bản agent khác nhau [13]. Các benchmark dạng này phản ánh nhu cầu đánh giá agent ở nhiều bước, nhiều công cụ và nhiều loại hành vi, thay vì chỉ kiểm tra response cuối.

Một benchmark agent security nên bao gồm ít nhất các thành phần sau:

1. **Benign tasks:** nhiệm vụ hợp lệ để đo task utility;
2. **Adversarial tasks:** nhiệm vụ hoặc môi trường có injection để đo robustness;
3. **Tool environment:** tập công cụ, quyền hạn và dữ liệu bên ngoài;
4. **Security policy:** định nghĩa rõ hành vi nào được phép hoặc không được phép;
5. **Trajectory logs:** ghi lại kế hoạch, tool calls, tool outputs và final response;
6. **Scoring functions:** đo task success, security violation, over-defense, cost và latency.

Khác với benchmark text-only, benchmark agent cần đánh giá cả hai mục tiêu: agent phải hoàn thành nhiệm vụ hợp lệ và không bị hijack bởi dữ liệu không đáng tin cậy. Nếu defense chặn mọi tool call để đạt security cao, agent có thể mất utility. Nếu agent ưu tiên hoàn thành nhiệm vụ mà bỏ qua kiểm soát an toàn, security violation có thể tăng.

6.9 Tổng kết chương

Chương này đã mở rộng bài toán jailbreak từ chatbot sang agentic systems. Trong chatbot, rủi ro thường tập trung vào phản hồi văn bản. Trong agent, rủi ro xuất hiện trên toàn bộ trajectory, bao gồm prompt, external content, memory, plan, tool call, tool output, action và environment.

Các dạng rủi ro chính gồm direct prompt injection, indirect prompt injection, tool-use attacks, memory poisoning và jailbreak đối với hệ thống robot được điều khiển bởi LLM. Điểm chung của các rủi ro này là chúng khai thác việc agent đưa dữ liệu không đáng tin cậy vào quá trình ra quyết định.

Do đó, phòng thủ cho agent cần vượt ra ngoài input/output moderation. Một hệ thống agent an toàn cần context isolation, permission control, action validation, memory access control, trajectory monitoring, sandboxing và human confirmation cho hành động rủi ro cao. Đồng thời, evaluation cần đo cả task utility và security violation trên toàn bộ trajectory.

Chương tiếp theo phân tích các công trình tiêu biểu được tutorial đề cập, bao gồm các attack, defense và benchmark đại diện cho từng hướng nghiên cứu.

7 Các công trình tiêu biểu trong tutorial

Các chương trước đã trình bày nền tảng, các nhóm jailbreak attacks, jailbreak defenses, phương pháp đánh giá và sự mở rộng của bài toán sang agentic systems. Chương này tổng hợp và phân tích các công trình tiêu biểu được đề cập trong tutorial ICML 2025 *Jailbreaking LLMs and Agentic Systems: Attacks, Defenses, and Evaluations*. Mục tiêu của chương không phải là bao quát toàn bộ literature về jailbreaking, mà là làm rõ vai trò của các paper trung tâm trong từng nhóm nội dung: attack, defense, evaluation và agentic/robotic systems.

Khác với Chương 3 và Chương 4, chương này không đi sâu vào cơ chế kỹ thuật của từng nhóm phương pháp. Thay vào đó, mỗi công trình được đặt vào bối cảnh chung của tutorial để làm rõ câu hỏi: paper đó đại diện cho hướng nghiên cứu nào, đóng góp chính là gì, và tại sao nó quan trọng đối với bài toán jailbreak.

7.1 Các công trình về jailbreak attacks

Nhóm attack papers trong tutorial cho thấy sự phát triển của jailbreak từ các prompt thủ công sang các phương pháp tự động, có khả năng tối ưu, tìm kiếm, chuyển giao và thích nghi với mô hình mục tiêu.

7.1.1 Universal and Transferable Adversarial Attacks

Công trình *Universal and Transferable Adversarial Attacks on Aligned Language Models* là một trong những paper trung tâm nhất của phần attack [2]. Tutorial sử dụng công trình này để minh họa hướng white-box jailbreak dựa trên adversarial suffix và thuật toán Greedy Coordinate Gradient (GCG).

Ý tưởng chính của paper là tìm một chuỗi token bổ sung được nối vào yêu cầu ban đầu nhằm làm suy yếu hành vi từ chối của mô hình. Nếu x là yêu cầu gốc và a là adversarial suffix, đầu vào sau tấn công có dạng

$$x' = x \oplus a, \quad (29)$$

trong đó $\oplus$ là phép nối chuỗi. Suffix a được tối ưu để làm tăng khả năng mô hình tạo phản hồi theo hướng attacker mong muốn. Về mặt khái quát, bài toán có thể được biểu diễn bởi

$$a^* = \arg \min_{a \in \mathcal{V}^m} \mathcal{L}(F_\theta(x \oplus a)), \quad (30)$$

trong đó $\mathcal{V}$ là vocabulary, m là độ dài suffix và $\mathcal{L}$ là hàm mất mát dùng để hướng đầu ra của mô hình.

Vai trò của công trình này trong tutorial là làm rõ ba điểm. Thứ nhất, jailbreak có thể được xây dựng bằng tối ưu hóa, không chỉ bằng prompt thủ công. Thứ hai, các chuỗi adversarial có thể có hình thức không tự nhiên đối với con người nhưng vẫn tạo tác động lớn lên mô hình. Thứ ba, một số attack có khả năng transfer giữa các mô hình, cho thấy các mô hình khác nhau có thể chia sẻ điểm yếu trong cơ chế safety alignment.

7.1.2 PAIR

Công trình *Jailbreaking Black Box Large Language Models in Twenty Queries* giới thiệu PAIR, một phương pháp black-box automated jailbreak [3]. Đây cũng là một paper được tutorial trình bày sâu vì nó minh họa cách jailbreak có thể được tự động hóa ngay cả khi attacker không có quyền truy cập tham số, gradient hoặc logit của mô hình.

PAIR sử dụng ba thành phần chính: attacker model, target model và judge. Attacker model sinh candidate prompt; target model phản hồi; judge đánh giá mức độ thành công; sau đó attacker model tinh chỉnh prompt dựa trên kết quả quan sát được. Quy trình này có thể được mô tả khái quát bởi

$$x_{t+1} = A_{\phi}(x_t, y_t, J(x_t, y_t)), \quad (31)$$

trong đó A_{ϕ} là attacker model, x_t là prompt tại vòng lặp thứ t , y_t là phản hồi của target model và J là evaluator.

Đóng góp chính của PAIR là chuyển jailbreak từ một hoạt động thủ công sang một vòng lặp automated red teaming. Paper này cũng làm rõ một threat model quan trọng trong thực tế: nhiều hệ thống thương mại chỉ cho phép truy cập black-box qua API, nhưng điều đó không ngăn attacker sử dụng một mô hình khác để tự động sinh và cải tiến prompt tấn công.

7.1.3 Tree of Attacks

Tree of Attacks: Jailbreaking Black-Box LLMs Automatically mở rộng hướng black-box automated jailbreak bằng cách sử dụng tìm kiếm dạng cây [5]. Nếu PAIR tinh chỉnh prompt theo một chuỗi lặp, thì Tree of Attacks duy trì nhiều candidate prompts song song, mở rộng các nhánh có triển vọng và loại bỏ các nhánh kém hiệu quả.

Có thể mô tả tập candidate ở bước t là

$$\mathcal{C}_t = \{x_t^{(1)}, x_t^{(2)}, \dots, x_t^{(k)}\}. \quad (32)$$

Sau bước mở rộng và pruning, hệ thống giữ lại tập con có khả năng thành công cao hơn:

$$\mathcal{C}_{t+1} = \text{Prune}(\text{Expand}(\mathcal{C}_t)). \quad (33)$$

Vai trò của paper này trong tutorial là minh họa rằng black-box jailbreak không chỉ có thể được tự động hóa, mà còn có thể được tổ chức như một bài toán search. Điều này đặc biệt quan trọng khi ngân sách truy vấn bị giới hạn: một chiến lược tìm kiếm tốt có thể giảm số lần thử kém hiệu quả và tập trung vào các hướng có khả năng thành công cao hơn.

7.1.4 AutoDAN

AutoDAN: Generating Stealthy Jailbreak Prompts on Aligned Large Language Models đại diện cho hướng tự động tạo jailbreak prompt có hình thức tự nhiên và khó phát hiện hơn so với adversarial suffix thông thường **liu2023autodan**. Nếu GCG có thể sinh ra các chuỗi token bất thường, AutoDAN nhấn mạnh tính *stealthy*: prompt được tạo ra cần vừa có khả năng tấn công, vừa ít bị phát hiện bởi các defense dựa trên bất thường bề mặt.

Vai trò của AutoDAN trong tutorial là bổ sung một góc nhìn quan trọng: không phải mọi jailbreak tự động đều tạo ra chuỗi token khó đọc. Một attack có thể được tối ưu để trông tự nhiên hơn, khiến input filtering hoặc các heuristic phát hiện prompt lạ trở nên kém hiệu quả. Điều này làm rõ giới hạn của các defense chỉ dựa trên đặc trưng bề mặt.

7.1.5 Automated red teaming và reasoning-based search

Tutorial cũng đề cập đến các hướng automated red teaming rộng hơn, chẳng hạn *Red Teaming Language Models with Language Models* **perez2022redteaming** và *Adversarial Reasoning at Scale*. Các công trình này đặt nền tảng cho ý tưởng dùng mô hình ngôn ngữ hoặc test-time computation để tự động tìm các hành vi lỗi của một hệ thống khác.

Điểm chung của nhóm này là thay vì chỉ kiểm thử mô hình bằng một tập prompt cố định, quá trình đánh giá được mở rộng thành một vòng lặp tìm kiếm chủ động. Một mô hình hoặc một hệ thống search đóng vai trò red teamer, sinh ra các tình huống kiểm thử, quan sát phản hồi của target model và tiếp tục mở rộng các trường hợp có rủi ro. Đây là tiền đề quan trọng cho các phương pháp như PAIR, TAP và các framework automated red teaming sau này.

7.2 Các công trình về jailbreak defenses

Nhóm defense papers trong tutorial cho thấy các phương pháp phòng thủ đã phát triển từ input/output filtering đơn giản sang inference-time defense, representation-level defense và các cơ chế can thiệp sâu hơn vào hành vi mô hình.

7.2.1 SmoothLLM

SmoothLLM: Defending Large Language Models Against Jailbreaking Attacks là công trình trung tâm trong phần defense của tutorial [6]. SmoothLLM là một inference-time defense, tức là nó không yêu cầu huấn luyện lại mô hình chính. Thay vào đó, phương pháp tạo nhiều biến thể nhỏ của cùng một prompt và kiểm tra độ ổn định của phản hồi.

Với prompt đầu vào x , SmoothLLM tạo ra K biến thể

$$\tilde{x}_1, \tilde{x}_2, \dots, \tilde{x}_K \sim \mathcal{P}(x), \quad (34)$$

trong đó $\mathcal{P}$ là phân phối perturbation. Sau đó, hệ thống truy vấn mô hình trên các biến thể này và tổng hợp kết quả:

$$d = g(F_\theta(\tilde{x}_1), F_\theta(\tilde{x}_2), \dots, F_\theta(\tilde{x}_K)). \quad (35)$$

Ý tưởng cốt lõi là nhiều adversarial prompts, đặc biệt là các prompt được tối ưu ở mức token hoặc ký tự, có tính giòn trước các biến đổi nhỏ. SmoothLLM khai thác đặc điểm này để phát hiện hoặc làm giảm hiệu quả của jailbreak.

Vai trò của SmoothLLM trong tutorial là minh họa một defense có thể triển khai ở runtime, độc lập tương đối với mô hình chính. Tuy nhiên, tutorial cũng nhấn mạnh hạn chế của hướng này: chi phí suy luận tăng do cần nhiều lần gọi mô hình, và defense có thể bị thách thức bởi adaptive attacks hoặc các prompt có tính ổn định ngữ nghĩa cao hơn.

7.2.2 Circuit Breakers

Circuit Breakers: Enhanced Safety in LLMs via Representation Rerouting đại diện cho nhóm model-level defense **zou2024circuit**. Thay vì chỉ kiểm tra input hoặc output, hướng này tìm cách can thiệp vào biểu diễn bên trong của mô hình để ngăn mô hình đi vào các trạng thái biểu diễn liên quan đến hành vi không an toàn.

Khác với SmoothLLM, Circuit Breakers không chỉ là một wrapper bên ngoài. Nó hướng đến việc thay đổi cách mô hình xử lý các yêu cầu rủi ro ở tầng representation. Về mặt trực giác, khi mô hình bắt đầu đi theo một hướng kích hoạt có khả năng dẫn đến phản hồi không an toàn, defense sẽ reroute hoặc can thiệp để đưa mô hình về hành vi an toàn hơn.

Vai trò của paper này trong tutorial là cho thấy defense có thể được đặt ở mức sâu hơn so với input/output filtering. Tuy nhiên, các phương pháp dạng này thường yêu cầu quyền truy cập vào mô hình hoặc quá trình huấn luyện, nên khó áp dụng trực tiếp cho các API đóng.

7.2.3 Representation Guardrails

Nhóm *Representation Guardrails* cũng thuộc hướng representation-level defense. Thay vì chỉ dựa vào nội dung văn bản của prompt hoặc response, các phương pháp này khai thác hidden representations, activation patterns hoặc embedding space để phát hiện và kiểm soát hành vi không an toàn.

Vai trò của nhóm này trong tutorial là bổ sung một tầng phòng thủ khác: nếu attacker có thể làm prompt trông tự nhiên ở bề mặt, hệ thống vẫn có thể phát hiện tín hiệu rủi ro trong biểu diễn bên trong của mô hình. Tuy nhiên, giống Circuit Breakers, representation-level guardrails thường khó triển khai hơn trong bối cảnh mô hình đóng và cần đánh giá cẩn thận để tránh làm giảm utility.

7.2.4 Instruction-following và utility evaluation

Tutorial cũng nhắc đến hướng đánh giá ảnh hưởng của defense đến khả năng làm theo chỉ dẫn hợp lệ. Đây là điểm quan trọng vì một defense không thể chỉ được đánh giá bằng việc giảm Attack Success Rate. Nếu defense khiến mô hình từ chối quá nhiều yêu cầu hợp lệ hoặc làm giảm khả năng instruction following, hệ thống sẽ mất utility.

Do đó, các paper và benchmark về instruction-following evaluation được dùng trong tutorial như một lời nhắc rằng defense phải được đánh giá theo cả hai chiều: giảm unsafe compliance và hạn chế over-refusal.

7.3 Các benchmark và phương pháp đánh giá

Nhóm benchmark và evaluation papers trong tutorial giải quyết vấn đề: làm thế nào để so sánh attack và defense một cách công bằng. Nếu mỗi công trình dùng một tập prompt, target model, system prompt và evaluator khác nhau, kết quả sẽ khó đối chiếu. Vì vậy, các benchmark như AdvBench, HarmBench và JailbreakBench đóng vai trò quan trọng trong việc chuẩn hóa đánh giá.

7.3.1 AdvBench

AdvBench là tập harmful behaviors được sử dụng phổ biến trong nghiên cứu jailbreak, đặc biệt trong các công trình về adversarial suffix như GCG [2]. Benchmark này cung cấp các yêu cầu rủi ro dạng text-only để kiểm tra liệu attack có khiến mô hình tạo phản hồi không an toàn hay không.

Vai trò của AdvBench trong tutorial là làm ví dụ cho một tập hành vi chuẩn dùng để đánh giá attack. Tuy nhiên, AdvBench không bao phủ toàn bộ không gian rủi ro, đặc biệt là multi-turn jailbreak, prompt injection trong agentic systems hoặc tool-use attacks. Vì vậy, nó phù hợp cho đánh giá ban đầu nhưng cần kết hợp với các benchmark rộng hơn.

7.3.2 HarmBench

HarmBench: A Standardized Evaluation Framework for Automated Red Teaming and Robust Refusal là benchmark quan trọng trong phần evaluation [8]. HarmBench không chỉ là một tập prompt, mà là một framework đánh giá có cấu trúc cho automated red teaming và robust refusal.

HarmBench chuẩn hóa nhiều thành phần: behavior set, attack methods, target models, defenses và evaluator. Điều này giúp kết quả giữa các phương pháp dễ so sánh hơn. Trong tutorial, HarmBench đại diện cho nỗ lực đưa jailbreak evaluation từ các thử nghiệm rời rạc sang quy trình đánh giá có kiểm soát.

Điểm quan trọng của HarmBench là khái niệm *robust refusal*. Một mô hình không chỉ cần từ chối yêu cầu không an toàn trong điều kiện thông thường, mà còn phải duy trì từ chối trước các biến thể attack khác nhau.

7.3.3 JailbreakBench

JailbreakBench: An Open Robustness Benchmark for Jailbreaking Large Language Models nhấn mạnh tính mở, khả năng tái lập và chuẩn hóa benchmark [9]. Benchmark này cung cấp attack artifacts, behavior set, target models, scoring functions và leaderboard để so sánh attack-defense trong một thiết lập rõ ràng.

Vai trò của JailbreakBench trong tutorial là làm rõ rằng evaluation không chỉ là tính ASR trên một tập prompt. Một benchmark tốt cần công bố threat model, system prompt, chat template, scoring rule và điều kiện đánh giá. Điều này đặc biệt quan trọng trong nghiên cứu jailbreak vì kết quả có thể thay đổi mạnh theo target model, system prompt, evaluator và ngân sách truy vấn.

7.3.4 Trojan Detection Challenge

Trojan Detection Challenge (TDC) được tutorial nhắc đến như một nguồn hoặc benchmark liên quan đến đánh giá hành vi tấn công, backdoor hoặc trojan. TDC không phải trung tâm của jailbreak text-only, nhưng có giá trị như một điểm liên hệ với các hướng an toàn mô hình rộng hơn.

Trong báo cáo này, TDC được xem là benchmark bổ trợ, giúp phân biệt jailbreak tại thời điểm suy luận với các rủi ro khác như backdoor hoặc trojan được cài trong mô hình. Nội dung này cũng nhấn mạnh rằng jailbreak chỉ là một phần của bức tranh an toàn AI rộng hơn.

7.4 Các công trình về robotics và agentic systems

Phần cuối của tutorial mở rộng bài toán từ chatbot sang agentic systems và robotics. Trong bối cảnh này, rủi ro không chỉ nằm ở phản hồi văn bản mà còn nằm ở kế hoạch,

lời gọi công cụ, memory, observation và hành động trong môi trường.

7.4.1 RoboPAIR

RoboPAIR: Jailbreaking LLM-Controlled Robots là paper trung tâm trong phần robotics của tutorial [11]. Công trình này mở rộng tinh thần của PAIR sang các hệ thống robot do LLM điều khiển. Thay vì chỉ đánh giá xem mô hình có tạo phản hồi không an toàn hay không, RoboPAIR xem xét liệu hệ thống robot có thể bị dẫn đến hành động trái với ràng buộc an toàn hay không.

Vai trò của RoboPAIR trong tutorial là rất quan trọng vì nó thay đổi đơn vị đánh giá của jailbreak. Với chatbot, output chính là văn bản. Với robot, output có thể là hành động vật lý. Vì vậy, một defense chỉ kiểm tra phản hồi cuối cùng là không đủ. Hệ thống cần kiểm soát kế hoạch, lời gọi hành động, controller, môi trường và cơ chế dừng an toàn.

RoboPAIR cho thấy khi LLM được tích hợp vào embodied agents, jailbreak không còn là vấn đề của ngôn ngữ đơn thuần. Nó trở thành vấn đề an toàn hệ thống, trong đó controller, permission, sandbox, monitoring và human confirmation đều đóng vai trò quan trọng.

7.4.2 AgentDojo

AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents là benchmark được tutorial nhắc đến trong phần agentic systems [12]. AgentDojo tập trung vào đánh giá prompt injection attacks và defenses trong môi trường agent có khả năng sử dụng công cụ.

Điểm quan trọng của AgentDojo là nó đánh giá đồng thời utility và security. Một agent phải hoàn thành nhiệm vụ hợp lệ của người dùng, nhưng không được bị thao túng bởi dữ liệu hoặc chỉ dẫn không đáng tin cậy. Điều này phản ánh đúng thách thức của agentic systems: defense quá yếu làm tăng security violation, nhưng defense quá mạnh có thể làm agent không hoàn thành nhiệm vụ.

Trong tutorial, AgentDojo đại diện cho hướng benchmark động, nơi agent tương tác với môi trường và công cụ thay vì chỉ trả lời một prompt tĩnh.

7.4.3 BrowserART và Breaking ReAct

BrowserART và *Breaking ReAct* được tutorial dẫn như các công trình liên quan đến bảo mật của web/browser agents và ReAct agents. Các hệ thống này đặc biệt dễ gặp rủi ro vì agent phải quan sát nội dung từ môi trường bên ngoài, suy luận dựa trên observation và gọi công cụ hoặc hành động tiếp theo.

Breaking ReAct làm rõ một điểm quan trọng: trong các agent dùng mô hình observation–reasoning–action, attacker có thể tác động không chỉ vào prompt ban đầu mà còn vào observation hoặc tool output. Nếu agent không phân biệt rõ dữ liệu với

instruction, nội dung bên ngoài có thể ảnh hưởng đến quá trình reasoning và dẫn đến hành động sai.

BrowserART đại diện cho hướng đánh giá web agents trong môi trường trình duyệt, nơi rủi ro có thể đến từ website, form, nội dung được render, hoặc chỉ dẫn gián tiếp nằm trong trang web. Các benchmark dạng này giúp mở rộng evaluation từ text-only jailbreak sang các tác vụ web thực tế hơn.

7.5 So sánh các công trình tiêu biểu

Bảng 10 tổng hợp các công trình tiêu biểu được tutorial đề cập theo từng nhóm nội dung.

Bảng 10: Các công trình tiêu biểu được tutorial đề cập theo từng nhóm nội dung.

Nhóm nội dung	Công trình tiêu biểu	Vai trò trong tutorial
White-box jailbreak	Universal and Transferable Adversarial Attacks	Đại diện cho adversarial suffix, thuật toán GCG và khả năng transfer giữa các mô hình.
Black-box automated jailbreak	PAIR; Tree of Attacks	Đại diện cho attacker–target–judge, iterative refinement và search-based jailbreak trong black-box setting.
Stealthy jailbreak generation	AutoDAN	Mình họa hướng tự động tạo jailbreak prompt tự nhiên hơn và khó phát hiện hơn so với adversarial suffix bất thường.
Automated red teaming	Red Teaming Language Models with Language Models; Adversarial Reasoning at Scale	Cung cấp nền tảng cho việc dùng mô hình ngôn ngữ hoặc test-time computation để tự động tìm hành vi lỗi.
Inference-time defense	SmoothLLM	Đại diện cho defense không cần huấn luyện lại mô hình, dựa trên nhiều perturbation của prompt và tổng hợp phản hồi.
Model-level defense	Circuit Breakers; Representation Guardrails	Đại diện cho hướng phát hiện hoặc can thiệp vào representation bên trong mô hình để hạn chế hành vi không an toàn.
Evaluation benchmarks	AdvBench; HarmBench; JailbreakBench; TDC	Đại diện cho các tập hành vi, framework đánh giá automated red teaming, robust refusal và benchmark mở cho jailbreak robustness.
Agentic systems	AgentDojo; BrowserART; Breaking ReAct	Đại diện cho đánh giá prompt injection, tool-use risks và security của LLM agents trong môi trường có công cụ.
Robotics	RoboPAIR	Đại diện cho việc mở rộng jailbreak từ phản hồi văn bản sang hành động trong robot được điều khiển bởi LLM.

Từ bảng trên, có thể thấy tutorial không chỉ trình bày jailbreak như một tập prompt tấn công riêng lẻ. Thay vào đó, tutorial tổ chức lĩnh vực này theo một chuỗi phát triển rộng hơn: từ attack thủ công sang attack tự động, từ defense ở bề mặt input/output sang defense ở mức representation, từ evaluation rời rạc sang benchmark chuẩn hóa, và từ chatbot sang agentic systems hoặc robot.

7.6 Nhận xét chung

Từ các paper được tutorial đề cập, có thể rút ra bốn nhận xét chính.

Thứ nhất, jailbreak đang chuyển từ prompt engineering thủ công sang automated red teaming. GCG, PAIR, Tree of Attacks, AutoDAN và các hướng reasoning-based search cho thấy attacker có thể dùng tối ưu hóa, mô hình ngôn ngữ hoặc search để tự động tìm prompt hiệu quả hơn.

Thứ hai, defense không thể chỉ dựa vào một lớp duy nhất. SmoothLLM cho thấy có thể phòng thủ tại thời điểm suy luận; Circuit Breakers và Representation Guardrails cho thấy khả năng phòng thủ ở tầng representation; nhưng mỗi hướng đều có giới hạn về chi phí, quyền truy cập mô hình và khả năng chống adaptive attacks.

Thứ ba, evaluation là yếu tố trung tâm để so sánh attack và defense. AdvBench cung cấp tập harmful behaviors phổ biến; HarmBench chuẩn hóa automated red teaming và robust refusal; JailbreakBench nhấn mạnh artifacts, scoring functions và reproducibility. Điều này cho thấy một kết quả ASR chỉ có ý nghĩa khi đi kèm threat model, target model, system prompt, evaluator và ngân sách truy vấn.

Thứ tư, agentic systems làm thay đổi bản chất của bài toán. RoboPAIR, AgentDojo, BrowserART và Breaking ReAct cho thấy khi LLM có memory, tools, browser hoặc robot embodiment, rủi ro không chỉ nằm ở phản hồi cuối cùng. Cần đánh giá toàn bộ trajectory, bao gồm observation, reasoning, tool call, action và environment state.

7.7 Tổng kết chương

Chương này đã tổng hợp các công trình tiêu biểu được đề cập trong tutorial ICML 2025 về jailbreaking LLMs và agentic systems. Các paper về attack như GCG, PAIR, Tree of Attacks và AutoDAN cho thấy jailbreak có thể được tối ưu và tự động hóa. Các paper về defense như SmoothLLM, Circuit Breakers và Representation Guardrails cho thấy phòng thủ có thể được triển khai ở nhiều tầng khác nhau, từ runtime đến representation nội bộ của mô hình. Các benchmark như AdvBench, HarmBench và JailbreakBench làm rõ nhu cầu chuẩn hóa evaluation. Cuối cùng, RoboPAIR, AgentDojo, BrowserART và Breaking ReAct mở rộng bài toán sang agentic systems, nơi mô hình có thể dùng công cụ hoặc thực hiện hành động trong môi trường.

Những công trình này tạo nền tảng cho phần thực nghiệm ở Chương ??, nơi báo

cáo xây dựng một demo có kiểm soát để minh họa attack–defense pipeline, cách đo lường safety–utility trade-off và các giới hạn của đánh giá thực nghiệm.

Tài liệu tham khảo

- [1] S. Yi **and others**, ?Jailbreak Attacks and Defenses Against Large Language Models: A Survey,? *arXiv preprint arXiv:2407.04295*, 2024. **url:** <https://arxiv.org/abs/2407.04295>
- [2] A. Zou, Z. Wang, N. Carlini, M. Nasr, J. Z. Kolter **and** M. Fredrikson, ?Universal and Transferable Adversarial Attacks on Aligned Language Models,? *arXiv preprint arXiv:2307.15043*, 2023. **url:** <https://arxiv.org/abs/2307.15043>
- [3] P. Chao, A. Robey, E. Dobriban, H. Hassani, G. J. Pappas **and** E. Wong, ?Jailbreaking Black Box Large Language Models in Twenty Queries,? *arXiv preprint arXiv:2310.08419*, 2023. **url:** <https://arxiv.org/abs/2310.08419>
- [4] ICML Tutorial, *Jailbreaking LLMs and Agentic Systems: Attacks, Defenses, and Evaluations*, <https://jailbreak-tutorial.github.io/>, Tutorial at the International Conference on Machine Learning (ICML), 2025.
- [5] A. Mehrotra **and others**, ?Tree of Attacks: Jailbreaking Black-Box LLMs Automatically,? *arXiv preprint arXiv:2312.02119*, 2023. **url:** <https://arxiv.org/abs/2312.02119>
- [6] A. Robey, E. Wong, H. Hassani **and** G. J. Pappas, ?SmoothLLM: Defending Large Language Models Against Jailbreaking Attacks,? *arXiv preprint arXiv:2310.03684*, 2023. **url:** <https://arxiv.org/abs/2310.03684>
- [7] J. Ji **and others**, ?Defending Large Language Models against Jailbreak Attacks via Semantic Smoothing,? *arXiv preprint arXiv:2402.16192*, 2024. **url:** <https://arxiv.org/abs/2402.16192>
- [8] M. Mazeika **and others**, ?HarmBench: A Standardized Evaluation Framework for Automated Red Teaming and Robust Refusal,? *arXiv preprint arXiv:2402.04249*, 2024. **url:** <https://arxiv.org/abs/2402.04249>
- [9] P. Chao **and others**, ?JailbreakBench: An Open Robustness Benchmark for Jailbreaking Large Language Models,? *arXiv preprint arXiv:2404.01318*, 2024. **url:** <https://arxiv.org/abs/2404.01318>
- [10] K. Greshake, S. Abdelnabi, S. Mishra, C. Endres, T. Holz **and** M. Fritz, ?Not What You’ve Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection,? *arXiv preprint arXiv:2302.12173*, 2023. **url:** <https://arxiv.org/abs/2302.12173>
- [11] A. Robey, V. U. P. Ravichandran, V. Kumar, H. Hassani, G. J. Pappas **and** E. Wong, ?Jailbreaking LLM-Controlled Robots,? *arXiv preprint arXiv:2410.13691*, 2024. **url:** <https://arxiv.org/abs/2410.13691>

-
- [12] E. Debenedetti, J. Zhang, M. Balunovic, L. Beurer-Kellner, M. Fischer **and** F. Tramèr, ?AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents,? *arXiv preprint arXiv:2406.13352*, 2024. **url:** <https://arxiv.org/abs/2406.13352>
- [13] H. Zhang **and others**, ?Agent Security Bench (ASB): Formalizing and Benchmarking Attacks and Defenses in LLM-based Agents,? *arXiv preprint arXiv:2410.02644*, 2024. **url:** <https://arxiv.org/abs/2410.02644>